Zeitschrift für Sinnzentrierte Psychologie
HERAUSGEGEBEN VOM INSTITUT FÜR SINNZENTRIERTE PSYCHOLOGIE

Jahrgang 1 · Heft 3 · Oktober 2026
S. 36–39 (Original) · Open Access · CC BY 4.0

ÜBERSICHTSARBEIT

Dialogsysteme und Chatbots für die psychische Gesundheit

Eine narrative Übersicht über die Evidenz von regelbasierten Systemen bis zu großen Sprachmodellen

Sora Pazer, Samuel R. Ashford und Eleanor M. Whitcombe
Institut für Sinnzentrierte Psychologie

Deutsche Übersetzung. Maßgeblich ist die englische Originalfassung.

ZUSAMMENFASSUNG

Dialogsysteme, häufig als Chatbots bezeichnet, werden zunehmend als niedrigschwellige Unterstützung für Menschen mit psychischen Belastungen angeboten. Diese narrative Übersichtsarbeit fasst die Entwicklung und die empirische Evidenz solcher Systeme zusammen, von frühen regelbasierten Programmen bis zu Agenten auf der Grundlage großer Sprachmodelle. Zunächst wird der technische Wandel von geskripteten Dialogen zu generativen Systemen und dessen Bedeutung für Vorhersagbarkeit und Sicherheit beschrieben. Anschließend werden frühe randomisierte und Beobachtungsstudien zu strukturierten Agenten wie Woebot und Wysa, systematische Übersichtsarbeiten und Metaanalysen des Feldes sowie die erste randomisierte kontrollierte Studie zu einem vollständig generativen Therapie-Chatbot erörtert. Insgesamt deuten die verfügbaren Studien auf kleine bis mittlere kurzfristige Verringerungen von Depressions- und Belastungssymptomen bei überwiegend positiver Akzeptanz durch die Nutzenden hin. Die Evidenz ist jedoch durch kleine Stichproben, kurze Nachbeobachtungszeiträume, hohe Abbruchquoten, schwache Vergleichsbedingungen wie Wartelisten oder reine Informationskontrollen, heterogene Ergebnismaße und eine häufige Beteiligung der Entwickler an der Forschung begrenzt. Die Sicherheit in Krisensituationen und fehlerhafte Ausgaben generativer Modelle sind noch unzureichend untersucht. Die Übersicht kommt zu dem Schluss, dass Dialogsysteme am besten als vielversprechende, aber unbewiesene Ergänzung menschlicher Versorgung zu verstehen sind, und benennt Prioritäten für die künftige Forschung.

Schlüsselwörter: Dialogsysteme · Chatbots · digitale psychische Gesundheit · große Sprachmodelle · narrative Übersicht

ABSTRACT

Conversational agents, often called chatbots, are increasingly offered as low-threshold support for people with psychological distress. This narrative review summarizes the development and the empirical evidence of such systems, from early rule-based programs to agents built on large language models. It first describes the technical shift from scripted dialogues to generative systems and the consequences of this shift for predictability and safety. It then discusses early randomized and observational studies of structured agents such as Woebot and Wysa, systematic reviews and meta-analyses of the field, and the first randomized controlled trial of a fully generative therapy chatbot. Overall, the available studies suggest small to moderate short-term reductions in symptoms of depression and distress, together with generally favorable user acceptance. However, the evidence is limited by small samples, short follow-up periods, high attrition, weak comparison conditions such as waitlists or information-only controls, heterogeneous outcome measures, and frequent involvement of developers in the research. Safety in crisis situations and erroneous output from generative models remain insufficiently studied. The review concludes that conversational agents are best understood as a promising but unproven complement to human care, and it identifies priorities for future research.

Keywords: conversational agents · chatbots · digital mental health · large language models · narrative review

1 Einleitung

Der Bedarf an psychologischer Hilfe übersteigt in vielen Ländern das verfügbare Angebot an ausgebildeten Fachkräften, und die Wartezeiten auf eine Psychotherapie sind oft lang. Digitale Interventionen wurden als ein Weg vorgeschlagen, diese Lücke zu verkleinern, und internetbasierte

psychologische Behandlungen, insbesondere angeleitete kognitiv-verhaltenstherapeutische Programme, stützen sich inzwischen auf eine umfangreiche Evidenzbasis (Andersson et al., 2019). Dialogsysteme stellen eine jüngere Entwicklung innerhalb dieses Feldes dar. Statt Module zum Lesen und Bearbeiten bereitzustellen, interagieren sie mit den Nutzenden im Dialog in natürlicher Sprache, meist in Textform.

Mit dem Aufkommen von Systemen auf der Grundlage großer Sprachmodelle hat das Thema neue Dringlichkeit erhalten. Solche Systeme können zu nahezu jedem Thema flüssige und scheinbar empathische Antworten erzeugen, und viele Menschen nutzen allgemeine Chatbots zur emotionalen Unterstützung, unabhängig davon, ob diese dafür entwickelt wurden. Die Frage, was über Nutzen und Risiken von Dialogsystemen im Bereich der psychischen Gesundheit tatsächlich bekannt ist, hat daher erhebliche praktische Bedeutung.

Diese narrative Übersichtsarbeit fasst die wesentlichen Entwicklungslinien und die Evidenz zusammen. Sie strebt weder eine systematische Recherche noch eine quantitative Synthese an, sondern stützt sich auf zentrale Primärstudien und veröffentlichte systematische Übersichtsarbeiten, um den Wissensstand, seine Grenzen und offene Fragen für Forschung und Praxis zu skizzieren.

2 Von regelbasierten Systemen zu großen Sprachmodellen

Die Geschichte der Dialogsysteme in der Psychologie beginnt üblicherweise mit ELIZA, einem Programm, das einen klientenzentrierten Therapeuten simulierte, indem es Schlüsselwörter erkannte und die Aussagen der Nutzenden in Fragen umformte (Weizenbaum, 1966). Obwohl der Mechanismus einfach war, schrieben Nutzende dem Programm bereitwillig Verständnis zu, ein Phänomen, das später als ELIZA-Effekt bezeichnet wurde.

Lange Zeit folgten die meisten Chatbots für die psychische Gesundheit einer regelbasierten oder abrufbasierten Logik. Die Dialoge wurden von Klinikerinnen und Klinikern sowie Entwicklern geskriptet, die Nutzenden wählten häufig zwischen vorgegebenen Antworten, und das System wählte Inhalte, etwa Psychoedukation oder Übungen aus der kognitiven Verhaltenstherapie, nach festen Entscheidungsregeln aus. Einige Systeme nutzten die Verarbeitung natürlicher Sprache, um Freitexteingaben zu klassifizieren, doch der Inhalt der Antworten blieb weitgehend vorab festgelegt (Laranjo et al., 2018; Vaidyam et al., 2019). Diese Bauweise schränkt die Flexibilität ein, macht das Verhalten des Systems aber vorhersagbar und überprüfbar.

Generative Agenten auf der Grundlage großer Sprachmodelle funktionieren anders. Sie erzeugen jede Antwort neu auf der Basis statistischer Muster, die aus sehr großen Textmengen gelernt wurden. Das ermöglicht offene, individualisierte Gespräche, bedeutet aber auch, dass der Inhalt einer bestimmten Antwort nicht vollständig im Voraus festgelegt werden kann. Generative Modelle können plausible, aber falsche oder unbelegte Aussagen hervorbringen, die oft als Halluzinationen bezeichnet werden (Ji et al., 2023). Für klinische Anwendungen bedeutet der Übergang von geskripteten zu generativen Systemen daher eine Verschiebung der zentralen Fragen: von der Frage, ob ein festes Programm wirksam ist, hin zu der Frage, wie das Verhalten eines flexiblen Systems begrenzt, überwacht und evaluiert werden kann (Stade et al., 2024).

3 Frühe Studien und Evaluationen unter Alltagsbedingungen

Eine der am häufigsten zitierten frühen Studien ist eine randomisierte kontrollierte Studie zu Woebot, einem regelbasierten Agenten, der jungen Erwachsenen mit depressiven und Angstsymptomen Elemente der kognitiven Verhaltenstherapie vermittelte (Fitzpatrick et al., 2017). Über einen Zeitraum von zwei Wochen berichteten Teilnehmende, die den Agenten nutzten, eine stärkere Abnahme depressiver Symptome als Teilnehmende einer reinen Informationskontrollbedingung, die auf ein elektronisches Selbsthilfebuch verwiesen wurden. Die Studie war klein, kurz und wurde von Forschenden durchgeführt, die mit dem entwickelnden Unternehmen verbunden waren, was die Autorinnen und Autoren offenlegten.

Wysa, ein Agent, der geskriptete Inhalte mit Freitextgesprächen verbindet, wurde in einer Mixed-Methods-Studie unter Alltagsbedingungen evaluiert (Inkster et al., 2018). Nutzende mit selbstberichteten depressiven Symptomen, die die App häufiger nutzten, zeigten im Mittel eine stärkere Verbesserung als weniger engagierte Nutzende. Da es keine randomisierte Kontrollgruppe gab und die Nutzungsintensität selbst gewählt war, lassen sich diese Ergebnisse nicht als Beleg für einen kausalen Effekt deuten. Spätere Arbeiten zu Woebot berichteten, dass Nutzende ihre Bindung an den Agenten auf einem Maß des Arbeitsbündnisses auf einem Niveau einschätzten, das mit dem für andere

Therapieformen berichteten vergleichbar war, wobei auch diese Befunde auf Beobachtungsdaten des Entwicklers beruhten (Darcy et al., 2021).

Auch Sicherheitsbedenken traten früh auf. Eine Studie zu allgemeinen Sprachassistenten fand, dass deren Antworten auf Äußerungen über Suizidgedanken, Depression oder interpersonelle Gewalt uneinheitlich und oft unvollständig waren (Miner et al., 2016). Obwohl diese Assistenten nicht als Werkzeuge für die psychische Gesundheit konzipiert waren, verdeutlichten die Befunde, wie sich Nutzende in Krisensituationen an Dialogsysteme wenden können, auf die diese Systeme nicht vorbereitet sind.

4 Systematische Übersichtsarbeiten und Metaanalysen

Frühe systematische Übersichtsarbeiten beschrieben ein heterogenes Feld mit wenigen kontrollierten Studien. Eine Übersicht über Dialogsysteme im Gesundheitswesen kam zu dem Schluss, dass die meisten Studien quasi-experimentell oder beobachtend angelegt waren und die Evidenz für klinische Wirksamkeit begrenzt war (Laranjo et al., 2018). Eine auf die Psychiatrie ausgerichtete Übersicht fand in mehreren Studien eine hohe Zufriedenheit und Beteiligung der Nutzenden, betonte jedoch den vorläufigen Charakter der Evidenz und die Notwendigkeit strengerer Evaluation (Vaidyam et al., 2019).

Eine Metaanalyse zu Chatbot-Interventionen für die psychische Gesundheit berichtete gewisse Hinweise auf Verbesserungen bei Depression, Belastung und Stress, bewertete die Gesamtevidenz jedoch als schwach, da nur wenige Studien vorlagen, das Verzerrungsrisiko hoch war und die Ergebnisse uneinheitlich waren (Abd-Alrazaq et al., 2020). Nur wenige Studien berichteten über Sicherheit. Eine spätere systematische Übersichtsarbeit mit Metaanalyse zu KI-basierten Dialogsystemen fand Verringerungen von Symptomen der Depression und psychischen Belastung, während die Effekte auf das psychische Wohlbefinden statistisch nicht signifikant waren (Li et al., 2023). Die Autorinnen und Autoren untersuchten zudem das Nutzungserleben und legten nahe, dass die Qualität der Mensch-KI-Interaktion und der Inhalt des Dialogs für die Ergebnisse bedeutsam sein könnten.

Zusammengenommen deuten diese Synthesen darauf hin, dass Dialogsysteme kurzfristige Symptomverbesserungen bewirken können, insbesondere bei Depression und Belastung, wobei die Effekte klein bis mittelgroß erscheinen. Breiter angelegte Übersichten zur digitalen Psychiatrie kommen zu einer ähnlichen Einschätzung und warnen, dass die Begeisterung der Evidenz häufig vorausgeeilt ist (Torous et al., 2021).

5 Die erste randomisierte Studie zu einem generativen Therapie-Chatbot

Ein jüngerer Meilenstein ist die erste randomisierte kontrollierte Studie zu einem vollständig generativen KI-Chatbot, der für die Behandlung psychischer Störungen entwickelt wurde (Heinz et al., 2025). Das System mit dem Namen Therabot wurde mit von Fachleuten kuratierten Dialogen auf der Grundlage evidenzbasierter Psychotherapie trainiert. Erwachsene mit klinisch bedeutsamen Symptomen einer Major Depression, einer generalisierten Angststörung oder einem erhöhten Risiko für Fütter- und Essstörungen wurden randomisiert einem mehrwöchigen Zugang zum Chatbot oder einer Wartelisten-Kontrollbedingung zugewiesen.

Die Autorinnen und Autoren berichteten in der Interventionsgruppe stärkere Symptomreduktionen in allen drei klinischen Bereichen sowie eine hohe Nutzungsbeteiligung. Die Einschätzungen des therapeutischen Arbeitsbündnisses durch die Teilnehmenden wurden als vergleichbar mit den für ambulante Psychotherapie berichteten Werten beschrieben. Klinikerinnen und Kliniker überwachten die Gespräche, und das Team griff bei Sicherheitsbedenken oder unangemessenen Antworten ein.

Die Studie ist bedeutsam, weil sie zeigt, dass ein generatives System mit einem randomisierten Design evaluiert werden kann. Zugleich ist ihre Interpretation begrenzt. Der Vergleich mit einer Warteliste erlaubt keine Aussagen über die Wirksamkeit im Vergleich zu aktiven Behandlungen oder einfacheren digitalen Programmen, der Nachbeobachtungszeitraum war kurz, und die umfangreiche menschliche Überwachung sowie das spezifische Trainingsverfahren bedeuten, dass die Ergebnisse nicht auf allgemeine Chatbots übertragen werden können, die ohne Aufsicht genutzt werden.

6 Methodische Grenzen und offene Fragen

In der gesamten Literatur kehren mehrere Grenzen wieder. Die Stichproben sind oft klein und stammen aus Gelegenheitspopulationen wie Studierenden oder App-Nutzenden. Die Nachbeobachtungszeiträume sind kurz, sodass die Dauerhaftigkeit der Effekte weitgehend unbekannt ist. Die Abbruchquoten sind häufig hoch, und der Umgang mit fehlenden Daten ist

uneinheitlich. Als Vergleichsbedingungen dienen meist Wartelisten oder reine Informationskontrollen, die Effekte im Vergleich zu aktiven Alternativen tendenziell überschätzen. Die Ergebnismaße sind heterogen, und viele Studien werden von den Entwicklern des jeweiligen Produkts durchgeführt oder finanziert (Abd-Alrazaq et al., 2020; Li et al., 2023).

Bei generativen Systemen kommen weitere Probleme hinzu. Modellversionen ändern sich rasch, was Replikationen erschwert und bedeutet, dass eine veröffentlichte Studie möglicherweise nicht mehr das System beschreibt, dem Nutzende tatsächlich begegnen. Fehlerhafte oder schädliche Ausgaben lassen sich konstruktionsbedingt nicht ausschließen (Ji et al., 2023), und Krisenerkennung sowie Weiterleitungswege werden selten systematisch evaluiert. Vorschläge für eine verantwortungsvolle Entwicklung empfehlen daher eine gestufte Evaluation, von Sicherheitstests bis zu kontrollierten Studien, unter durchgängiger Einbindung klinischer Expertise (Stade et al., 2024).

Schließlich ist wenig darüber bekannt, über welche Mechanismen Dialogsysteme wirken könnten. Ob eine wahrgenommene Bindung an einen Agenten in gleicher Weise zu den Ergebnissen beiträgt wie das Arbeitsbündnis in der menschlichen Psychotherapie und welche Rolle Sinn, Verantwortung und die eigene Reflexion der Nutzenden spielen, sind Fragen, die sowohl empirische als auch begriffliche Arbeit erfordern.

7 Fazit

Die Evidenz zu Dialogsystemen für die psychische Gesundheit ist im vergangenen Jahrzehnt erheblich gewachsen. Studien zu regelbasierten Agenten und Metaanalysen deuten auf bescheidene kurzfristige Vorteile bei Symptomen der Depression und Belastung hin, und die erste Studie zu einem generativen Therapie-Chatbot hat unter sorgfältig kontrollierten Bedingungen ermutigende Ergebnisse erbracht. Dennoch bleibt die Evidenz durch kurze Nachbeobachtung, schwache Vergleichsbedingungen, hohe Abbruchquoten und mögliche Interessenkonflikte begrenzt, und Sicherheitsfragen sind keineswegs gelöst.

Dialogsysteme sind daher am besten als vielversprechende, aber unbewiesene Ergänzung menschlicher Versorgung zu betrachten und nicht als deren Ersatz. Künftige Forschung sollte aktive Vergleichsbedingungen, längere Nachbeobachtung, eine transparente Berichterstattung über Modellversionen und Sicherheitsereignisse sowie unabhängige Evaluationen nutzen. Für eine sinnzentrierte Psychologie wird es zudem wichtig sein, nicht nur zu fragen, ob sich Symptome bessern, sondern auch, ob solche Werkzeuge die Fähigkeit eines Menschen stärken oder schwächen, zu seiner eigenen Situation Stellung zu nehmen.

Literatur

Abd-Alrazaq, A. A., Rababeh, A., Alajlani, M., Bewick, B. M., & Househ, M. (2020). Effectiveness and safety of using chatbots to improve mental health: Systematic review and meta-analysis. Journal of Medical Internet Research, 22(7), e16021. https://doi.org/10.2196/16021

Andersson, G., Titov, N., Dear, B. F., Rozental, A., & Carlbring, P. (2019). Internet-delivered psychological treatments: From innovation to implementation. World Psychiatry, 18(1), 20–28. https://doi.org/10.1002/wps.20610

Darcy, A., Daniels, J., Salinger, D., Wicks, P., & Robinson, A. (2021). Evidence of human-level bonds established with a digital conversational agent: Cross-sectional, retrospective observational study. JMIR Formative Research, 5(5), e27868. https://doi.org/10.2196/27868

Fitzpatrick, K. K., Darcy, A., & Vierhile, M. (2017). Delivering cognitive behavior therapy to young adults with symptoms of depression and anxiety using a fully automated conversational agent (Woebot): A randomized controlled trial. JMIR Mental Health, 4(2), e19. https://doi.org/10.2196/mental.7785

Heinz, M. V., Mackin, D. M., Trudeau, B. M., Bhattacharya, S., Wang, Y., Banta, H. A., Jewett, A. D., Salzhauer, A. J., Griffin, T. Z., & Jacobson, N. C. (2025). Randomized trial of a generative AI chatbot for mental health treatment. NEJM AI, 2(4), AIoa2400802. https://doi.org/10.1056/AIoa2400802

Inkster, B., Sarda, S., & Subramanian, V. (2018). An empathy-driven, conversational artificial intelligence agent (Wysa) for digital mental well-being: Real-world data evaluation mixed-methods study. JMIR mHealth and uHealth, 6(11), e12106. https://doi.org/10.2196/12106

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of hallucination in natural language generation. ACM Computing Surveys, 55(12), Article 248. https://doi.org/10.1145/3571730

Laranjo, L., Dunn, A. G., Tong, H. L., Kocaballi, A. B., Chen, J., Bashir, R., Surian, D., Gallego, B., Magrabi, F., Lau, A. Y. S., & Coiera, E. (2018). Conversational agents in healthcare: A systematic review. Journal of the American Medical Informatics Association, 25(9), 1248–1258. https://doi.org/10.1093/jamia/ocy072

Li, H., Zhang, R., Lee, Y.-C., Kraut, R. E., & Mohr, D. C. (2023). Systematic review and meta-analysis of AI-based conversational agents for promoting mental health and well-being. npj Digital Medicine, 6, 236. https://doi.org/10.1038/s41746-023-00979-5

Miner, A. S., Milstein, A., Schueller, S., Hegde, R., Mangurian, C., & Linos, E. (2016). Smartphone-based conversational agents and responses to questions about mental health, interpersonal violence, and physical health. JAMA Internal Medicine, 176(5), 619–625. https://doi.org/10.1001/jamainternmed.2016.0400

Stade, E. C., Stirman, S. W., Ungar, L. H., Boland, C. L., Schwartz, H. A., Yaden, D. B., Sedoc, J., DeRubeis, R. J., Willer, R., & Eichstaedt, J. C. (2024). Large language models could change the future of behavioral healthcare: A proposal for responsible development and evaluation. npj Mental Health Research, 3, 12. https://doi.org/10.1038/s44184-024-00056-z

Torous, J., Bucci, S., Bell, I. H., Kessing, L. V., Faurholt-Jepsen, M., Whelan, P., Carvalho, A. F., Keshavan, M., Linardon, J., & Firth, J. (2021). The growing field of digital psychiatry: Current evidence and the future of apps, social media, chatbots, and virtual reality. World Psychiatry, 20(3), 318–335. https://doi.org/10.1002/wps.20883

Vaidyam, A. N., Wisniewski, H., Halamka, J. D., Kashavan, M. S., & Torous, J. B. (2019). Chatbots and conversational agents in mental health: A review of the psychiatric landscape. The Canadian Journal of Psychiatry, 64(7), 456–464. https://doi.org/10.1177/0706743719828977

Weizenbaum, J. (1966). ELIZA—A computer program for the study of natural language communication between man and machine. Communications of the ACM, 9(1), 36–45. https://doi.org/10.1145/365153.365168

ZITIERVORSCHLAG (ORIGINALFASSUNG)

Pazer, S., Ashford, S. R., & Whitcombe, E. M. (2026). Conversational Agents and Chatbots for Mental Health: A narrative review of the evidence from rule-based systems to large language models. Journal of Meaning-Centered Psychology, 1(3), 36–39.

LIZENZ, KORRESPONDENZ UND EINSATZ VON KI

Erscheint im offenen Zugang unter der Lizenz Creative Commons Namensnennung 4.0 International (CC BY 4.0). Korrespondenz: Redaktion der Zeitschrift. Dieser Beitrag wurde mit Unterstützung generativer KI verfasst und von den Autorinnen und Autoren geprüft, die die volle Verantwortung für den Inhalt tragen.