Zeitschrift für Sinnzentrierte Psychologie
HERAUSGEGEBEN VOM INSTITUT FÜR SINNZENTRIERTE PSYCHOLOGIE

Jahrgang 1 · Heft 3 · Oktober 2026
S. 48–51 (Original) · Open Access · CC BY 4.0

METHODENBEITRAG

Die Evaluation KI-basierter psychologischer Interventionen

Studiendesigns, Kontrollbedingungen, Outcomes, Sicherheitsmonitoring und Berichtsstandards

Sora Pazer, Eleanor M. Whitcombe und Samuel R. Ashford
Institut für Sinnzentrierte Psychologie

Deutsche Übersetzung. Maßgeblich ist die englische Originalfassung.

ZUSAMMENFASSUNG

Konversationsagenten und andere KI-basierte Werkzeuge werden zunehmend als psychologische Interventionen angeboten, doch die Methoden ihrer Evaluation haben mit der technischen Entwicklung nicht Schritt gehalten. Dieser Methodenbeitrag skizziert die zentralen Designentscheidungen, von denen abhängt, ob eine Studie zu einer KI-basierten Intervention belastbare Schlussfolgerungen tragen kann. Zunächst verorten wir Evaluationsfragen entlang eines Entwicklungszyklus, von Machbarkeits- und Optimierungsstudien, einschließlich faktorieller, adaptiver und mikrorandomisierter Designs, bis hin zu konfirmatorischen randomisierten kontrollierten Studien. Anschließend erörtern wir die Wahl der Kontrollbedingungen und argumentieren, dass Wartelisten- und reine Informationskontrollen engere Fragen beantworten als häufig angenommen und dass für Aussagen über spezifische Wirkungen aufmerksamkeitsangeglichene oder aktive Vergleichsbedingungen erforderlich sind. Die Auswahl der Outcomes sollte validierte Symptommaße mit Indikatoren für Funktionsniveau, Nutzung und Studienabbruch verbinden, und die Katamnese sollte über die unmittelbare Postmessung hinausreichen. Generative Systeme stellen zusätzliche Anforderungen: ein prospektives Sicherheitsmonitoring mit vorab definierten unerwünschten Ereignissen, Verfahren zur Erkennung schädlicher oder fehlerhafter Ausgaben und die Dokumentation der während einer Studie verwendeten Modellversion und Konfiguration. Die Erweiterungen SPIRIT-AI und CONSORT-AI bieten einen Berichtsrahmen für diese Elemente. Wir folgern, dass methodische Sorgfalt eine Voraussetzung für jeden verantwortlichen klinischen Einsatz von KI in der Psychotherapie ist, auch in sinnzentrierten Ansätzen.

Schlüsselwörter: künstliche Intelligenz · randomisierte kontrollierte Studien · Kontrollbedingungen · Sicherheitsmonitoring · CONSORT-AI

ABSTRACT

Conversational agents and other AI-based tools are increasingly offered as psychological interventions, yet the methods used to evaluate them have not kept pace with their technical development. This methodological contribution outlines the main design decisions that determine whether a study of an AI-based intervention can support credible conclusions. We first locate evaluation questions along a development cycle, from feasibility and optimization studies, including factorial, adaptive and micro-randomized designs, to confirmatory randomized controlled trials. We then discuss the choice of control conditions, arguing that waitlist and information-only comparators answer narrower questions than is often assumed and that attention-matched or active comparators are needed for claims about specific benefits. Outcome selection should combine validated symptom measures with indicators of functioning, engagement and attrition, and follow-up should extend beyond the immediate post-treatment assessment. Generative systems add distinctive requirements: prospective safety monitoring with predefined adverse events, procedures for detecting harmful or inaccurate outputs, and documentation of the model version and configuration used throughout a trial. The SPIRIT-AI and CONSORT-AI extensions provide a reporting framework for these elements. We conclude that methodological rigor is a precondition for any responsible clinical use of AI in psychotherapy, including meaning-centered approaches.

Keywords: artificial intelligence · randomized controlled trials · control conditions · safety monitoring · CONSORT-AI

1 Einleitung

Innerhalb eines Jahrzehnts haben sich KI-basierte psychologische Interventionen von regelbasierten Konversationsagenten, die vorformulierte kognitiv-verhaltenstherapeutische Inhalte vermitteln, zu Systemen auf der Grundlage großer Sprachmodelle entwickelt, die offene Antworten generieren (Abd-Alrazaq et al., 2020; Torous et al., 2021). Frühe randomisierte Studien wie die Evaluation von Woebot bei jungen Erwachsenen (Fitzpatrick et al., 2017) und neuere Studien zu generativen Chatbots (Heinz et al., 2025) berichteten ermutigende Symptomveränderungen. Zugleich haben systematische Übersichtsarbeiten die Evidenzbasis wiederholt als heterogen, kurzfristig und von begrenzter methodischer Qualität beschrieben (Abd-Alrazaq et al., 2020).

Dieser Beitrag bietet keine Übersicht zur Wirksamkeit; diese Aufgabe wird an anderer Stelle in diesem Heft übernommen. Sein Ziel ist methodisch: Er beschreibt die Entscheidungen über Design, Vergleichsbedingungen, Outcomes, Sicherheitsmonitoring und Berichterstattung, die festlegen, was eine Studie zu einer KI-basierten Intervention zeigen kann und was nicht. Die Argumentation stützt sich auf etablierte Prinzipien der Psychotherapieforschung und auf die Berichtserweiterungen, die für Studien zu KI-Interventionen entwickelt wurden (Cruz Rivera et al., 2020; Liu et al., 2020). Leitend ist dabei eine bescheidene Frage: Was müsste eine skeptische, aber faire Leserin oder ein skeptischer, aber fairer Leser wissen, bevor sie oder er einem berichteten Nutzen vertraut?

2 Designs passend zum Entwicklungszyklus

Nicht jede Studie muss eine konfirmatorische randomisierte kontrollierte Studie (RCT) sein, aber jede Studie sollte angeben, welche Frage sie beantwortet. Mohr et al. (2017) argumentierten, dass die Forschung zu digitaler psychischer Gesundheit darunter gelitten hat, Produkte zu evaluieren, die sich schneller verändern, als Studien abgeschlossen werden können, und die Implementierungskontexte zu vernachlässigen, in denen die Werkzeuge tatsächlich eingesetzt werden. Eine sinnvolle Antwort besteht darin, Phasen zu unterscheiden: Machbarkeits- und Akzeptanzstudien, Optimierungsstudien, die wirksame Komponenten identifizieren, und konfirmatorische Studien, die eine festgelegte, genau spezifizierte Intervention gegen eine angemessene Vergleichsbedingung prüfen.

Für die Optimierungsphase erlauben die Multiphase Optimization Strategy (MOST) und Sequential Multiple Assignment Randomized Trials (SMART), Komponenten und adaptive Entscheidungsregeln zu untersuchen, bevor man sich auf ein vollständiges Paket festlegt (Collins et al., 2007). Mikrorandomisierte Studien, in denen Impulse oder Nachrichten innerhalb jeder teilnehmenden Person wiederholt randomisiert werden, eignen sich für Fragen nach den momentanen Effekten bestimmter Chatbot-Aktionen, etwa ob auf einen reflexiven Impuls nach berichteter gedrückter Stimmung in den folgenden Stunden eine bessere Bewältigung folgt (Klasnja et al., 2015). Solche Designs passen gut zu Konversationsagenten, weil einzelne Gesprächsbeiträge protokolliert und systematisch variiert werden können. Ihre Ergebnisse informieren jedoch die Gestaltung einer Intervention; sie belegen für sich genommen nicht deren klinische Wirksamkeit.

3 Kontroll- und Vergleichsbedingungen

Die Wahl der Vergleichsbedingung bestimmt die kausale Frage einer Studie. Mohr et al. (2009) zeigten für psychologische Interventionen allgemein, dass sich Kontrollbedingungen darin unterscheiden, inwieweit sie Erwartung, Aufmerksamkeit, Zeit und Kontakt kontrollieren, und dass diese Unterschiede Größe und Bedeutung der beobachteten Effekte prägen. Eine Wartelistenkontrolle, wie sie in der von Heinz et al. (2025) berichteten Studie zu einem generativen Chatbot verwendet wurde, beantwortet die Frage, ob das Angebot der Intervention für einen begrenzten Zeitraum besser ist als kein Angebot. Eine reine Informationskontrolle, wie in der frühen Woebot-Studie (Fitzpatrick et al., 2017), fügt eine minimale glaubwürdige Aktivität hinzu, entspricht aber nicht dem interaktiven, dialogischen Charakter der Intervention.

Aussagen darüber, dass ein Konversationsagent spezifische therapeutische Wirkungen hat, erfordern daher stärkere Vergleichsbedingungen. Infrage kommen aufmerksamkeitsangeglichene Kontrollen, etwa ein Konversationsagent, der mit den Nutzerinnen und Nutzern interagiert, ohne die vermuteten Wirkinhalte zu vermitteln; etablierte digitale Interventionen, etwa begleitete oder unbegleitete internetbasierte kognitive Verhaltenstherapie; und, wenn es um Ersatz geht, von Menschen erbrachte Behandlung. Jede Option bringt

Abwägungen hinsichtlich Durchführbarkeit, Verblindung und ethischer Vertretbarkeit mit sich. Da die Teilnehmenden in der Regel wissen, ob sie mit einem Chatbot interagieren, sollte die Erwartung zumindest zu Studienbeginn erhoben und die Glaubwürdigkeit der Kontrollbedingung geprüft statt vorausgesetzt werden. Nichtunterlegenheitsdesigns, auf die in diesem Zusammenhang häufig verwiesen wird, erfordern eine vorab festgelegte Grenze und eine ausreichend große Stichprobe.

4 Outcomes, Nutzung und Katamnese

Primäre Outcomes sollten validierte, klinisch bedeutsame und vorab festgelegte Maße sein, idealerweise ergänzt durch Erhebungen des Funktionsniveaus und der Lebensqualität. Für sinnzentrierte Ansätze können Maße des Lebenssinns als sekundäre Outcomes hinzugefügt werden, sofern ihre Aufnahme theoretisch begründet ist und nicht bloß auf Verfügbarkeit beruht. Outcomes, die ausschließlich innerhalb der Anwendung selbst erhoben werden, laufen Gefahr, Messung und Intervention zu vermengen, weil derselbe Gesprächskontext, der die Intervention vermittelt, auch die Selbstauskunft hervorruft. Wo klinische Fremdbeurteilungen möglich sind, sollten die Beurteilenden gegenüber der Gruppenzuteilung verblindet sein, und Verfahren der Fernerhebung sollten beschrieben werden.

Nutzung und Studienabbruch verdienen besondere Aufmerksamkeit. Eysenbach (2005) beschrieb ein „Gesetz des Schwunds“ in eHealth-Studien, und eine metaanalytische Übersicht zu smartphonebasierten Interventionen berichtete über erhebliche Abbruchraten in den einbezogenen Studien (Linardon & Fuller-Tyszkiewicz, 2020). Auswertungen sollten dem Intention-to-Treat-Prinzip folgen, fehlende Daten mit Verfahren behandeln, die dem angenommenen Ausfallmechanismus entsprechen, und die Nutzung detailliert berichten, zum Beispiel die Zahl der Sitzungen, Nachrichten und aktiven Tage. Nutzung sollte nicht als Stellvertreter für Nutzen behandelt werden: Intensive Verwendung kann Hilfreichkeit widerspiegeln, aber auch Abhängigkeit oder ungelöste Belastung. Schließlich können Katamnesezeiträume von wenigen Wochen, die nach wie vor häufig sind, nicht zeigen, ob Effekte anhalten; Designs sollten Erhebungen mehrere Monate nach Ende der aktiven Phase vorsehen.

5 Sicherheitsmonitoring und unerwünschte Ereignisse

Die Psychotherapieforschung hat seit Langem anerkannt, dass Interventionen Schaden verursachen können, und Konsensarbeiten zu Internetinterventionen empfehlen, negative Effekte systematisch zu definieren, zu überwachen und zu berichten (Rozental et al., 2014). Für KI-basierte Interventionen wird diese Verpflichtung konkreter. Studienprotokolle sollten festlegen, welche Ereignisse als unerwünscht gelten, etwa Symptomverschlechterung, neu auftretende Suizidgedanken, nicht angemessen behandelte Krisenmitteilungen oder Antworten, die schädliches Verhalten verstärken, und sie sollten beschreiben, wie solche Ereignisse erkannt, eskaliert und dokumentiert werden.

Generative Systeme bringen eine zusätzliche Risikoquelle mit sich: Sie können flüssige, aber falsche oder ungeeignete Inhalte erzeugen, ein Phänomen, das in der informatischen Literatur als Halluzination diskutiert wird (Ji et al., 2023). Das Sicherheitsmonitoring sollte daher von Teilnehmenden berichtete unerwünschte Ereignisse mit einer strukturierten Prüfung von Gesprächsprotokollen verbinden, zum Beispiel durch klinische Audits einer Zufallsstichprobe von Gesprächen sowie aller Gespräche, die von automatisierten Klassifikatoren markiert wurden. Heinz et al. (2025) beschrieben eine menschliche Aufsicht über die Chatbot-Antworten während ihrer Studie; solche Verfahren und die Häufigkeit, mit der Prüfende eingreifen mussten, gehören in den Studienbericht. Stade et al. (2024) haben eine gestufte Entwicklung und Evaluation von Anwendungen großer Sprachmodelle in der verhaltensbezogenen Gesundheitsversorgung vorgeschlagen, bei der Autonomie erst in dem Maße erweitert wird, in dem Sicherheitsevidenz vorliegt.

6 Modellversionierung, Transparenz und Berichterstattung

Eine konventionelle psychologische Intervention lässt sich in einem Manual beschreiben; ein System auf der Grundlage eines großen Sprachmodells wird durch das zugrunde liegende Modell, dessen Version, den Systemprompt, Abrufquellen, Sicherheitsfilter und Dekodierungseinstellungen bestimmt. Jedes dieser Elemente kann sich während einer Studie ändern, mitunter außerhalb der Kontrolle der Forschenden, wenn ein kommerzielles Modell über eine von einem Anbieter gepflegte Schnittstelle genutzt wird. Protokolle sollten die Konfiguration daher einfrieren

oder dokumentieren, jede Änderung mit Datum festhalten und Sensitivitätsanalysen für Zeiträume mit unterschiedlichen Versionen planen. Ohne diese Angaben lässt sich ein Studienergebnis keiner reproduzierbaren Intervention zuordnen. Prompttexte und Sicherheitsregeln sind Teil der Intervention und sollten, zumindest für Gutachtende, ebenso zugänglich gemacht werden wie Behandlungsmanuale.

Die Erweiterungen SPIRIT-AI und CONSORT-AI greifen diese Fragen für Protokolle und Berichte auf (Cruz Rivera et al., 2020; Liu et al., 2020). Unter anderem verlangen sie, die Version des KI-Systems anzugeben, zu beschreiben, wie Eingabedaten gewonnen und wie Eingaben schlechter Qualität oder fehlende Eingaben behandelt wurden, die Interaktion zwischen Mensch und KI sowie die Ausgabe des Systems zu spezifizieren und etwaige Analysen von Leistungsfehlern zu berichten. Obwohl diese Erweiterungen mit Blick auf diagnostische und entscheidungsunterstützende Anwendungen entwickelt wurden, lässt sich ihre Logik auf dialogische Interventionen übertragen. Präregistrierung, ein öffentlich zugängliches Protokoll und, soweit rechtlich und ethisch möglich, die Weitergabe anonymisierter Gesprächsbeispiele würden das Vertrauen weiter stärken.

7 Fazit

Die Evaluation KI-basierter psychologischer Interventionen erfordert keine neue Erkenntnistheorie, wohl aber die besonders sorgfältige Anwendung vertrauter Prinzipien. Die untersuchte Frage sollte zum Design passen; Vergleichsbedingungen sollten stark genug sein, um die erhobenen Aussagen zu tragen; Outcomes sollten über Symptome und über die ersten Wochen hinausreichen; die Sicherheit sollte prospektiv und transparent überwacht werden; und das evaluierte System sollte so genau dokumentiert sein, dass es wieder identifiziert werden kann. Keine dieser Anforderungen ist ungewöhnlich; die meisten gehören in Studien zu psychologischen und pharmakologischen Behandlungen bereits zum Standard.

Aus sinnzentrierter Perspektive hat methodische Sorgfalt auch eine ethische Dimension. Menschen, die sich in einer Notlage an ein digitales Werkzeug wenden, vertrauen ihm einen Teil ihrer Freiheit und Verantwortung an, und sie haben ein Recht darauf zu wissen, ob die ihnen angebotene Hilfe redlich geprüft wurde. Sorgfältige Evaluation ist daher kein Hindernis für Innovation, sondern eine Bedingung für deren verantwortlichen Gebrauch.

Literatur

Abd-Alrazaq, A. A., Rababeh, A., Alajlani, M., Bewick, B. M., & Househ, M. (2020). Effectiveness and safety of using chatbots to improve mental health: Systematic review and meta-analysis. Journal of Medical Internet Research, 22(7), e16021. https://doi.org/10.2196/16021

Collins, L. M., Murphy, S. A., & Strecher, V. (2007). The multiphase optimization strategy (MOST) and the sequential multiple assignment randomized trial (SMART): New methods for more potent eHealth interventions. American Journal of Preventive Medicine, 32(5 Suppl.), S112–S118. https://doi.org/10.1016/j.amepre.2007.01.022

Cruz Rivera, S., Liu, X., Chan, A.-W., Denniston, A. K., Calvert, M. J., & SPIRIT-AI and CONSORT-AI Working Group. (2020). Guidelines for clinical trial protocols for interventions involving artificial intelligence: The SPIRIT-AI extension. Nature Medicine, 26(9), 1351–1363. https://doi.org/10.1038/s41591-020-1037-7

Eysenbach, G. (2005). The law of attrition. Journal of Medical Internet Research, 7(1), e11. https://doi.org/10.2196/jmir.7.1.e11

Fitzpatrick, K. K., Darcy, A., & Vierhile, M. (2017). Delivering cognitive behavior therapy to young adults with symptoms of depression and anxiety using a fully automated conversational agent (Woebot): A randomized controlled trial. JMIR Mental Health, 4(2), e19. https://doi.org/10.2196/mental.7785

Heinz, M. V., Mackin, D. M., Trudeau, B. M., Bhattacharya, S., Wang, Y., Banta, H. A., Jewett, A. D., Salzhauer, A. J., Griffin, T. Z., & Jacobson, N. C. (2025). Randomized trial of a generative AI chatbot for mental health treatment. NEJM AI, 2(4). https://doi.org/10.1056/AIoa2400802

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of hallucination in natural language generation. ACM Computing Surveys, 55(12), Article 248. https://doi.org/10.1145/3571730

Klasnja, P., Hekler, E. B., Shiffman, S., Boruvka, A., Almirall, D., Tewari, A., & Murphy, S. A. (2015). Microrandomized trials: An experimental design for developing just-in-time adaptive interventions. Health Psychology, 34(Suppl.), 1220–1228. https://doi.org/10.1037/hea0000305

Linardon, J., & Fuller-Tyszkiewicz, M. (2020). Attrition and adherence in smartphone-delivered interventions for mental health problems: A systematic and meta-analytic review. Journal of Consulting and Clinical Psychology, 88(1), 1–13. https://doi.org/10.1037/ccp0000459

Liu, X., Cruz Rivera, S., Moher, D., Calvert, M. J., Denniston, A. K., & SPIRIT-AI and CONSORT-AI Working Group. (2020). Reporting guidelines for clinical trial reports for interventions involving artificial intelligence: The CONSORT-AI extension. Nature Medicine, 26(9), 1364–1374. https://doi.org/10.1038/s41591-020-1034-x

Mohr, D. C., Spring, B., Freedland, K. E., Beckner, V., Arean, P., Hollon, S. D., Ockene, J., & Kaplan, R. (2009). The selection and design of control conditions for randomized controlled trials of psychological interventions. Psychotherapy and Psychosomatics, 78(5), 275–284. https://doi.org/10.1159/000228248

Mohr, D. C., Weingardt, K. R., Reddy, M., & Schueller, S. M. (2017). Three problems with current digital mental health research . . . and three things we can do about them. Psychiatric Services, 68(5), 427–429. https://doi.org/10.1176/appi.ps.201600541

Rozental, A., Andersson, G., Boettcher, J., Ebert, D. D., Cuijpers, P., Knaevelsrud, C., Ljótsson, B., Kaldo, V., Titov, N., & Carlbring, P. (2014). Consensus statement on defining and measuring negative effects of Internet interventions. Internet Interventions, 1(1), 12–19. https://doi.org/10.1016/j.invent.2014.02.001

Stade, E. C., Stirman, S. W., Ungar, L. H., Boland, C. L., Schwartz, H. A., Yaden, D. B., Sedoc, J., DeRubeis, R. J., Willer, R., & Eichstaedt, J. C. (2024). Large language models could change the future of behavioral healthcare: A proposal for responsible development and evaluation. npj Mental Health Research, 3, 12. https://doi.org/10.1038/s44184-024-00056-z

Torous, J., Bucci, S., Bell, I. H., Kessing, L. V., Faurholt-Jepsen, M., Whelan, P., Carvalho, A. F., Keshavan, M., Linardon, J., & Firth, J. (2021). The growing field of digital psychiatry: Current evidence and the future of apps, social media, chatbots, and virtual reality. World Psychiatry, 20(3), 318–335. https://doi.org/10.1002/wps.20883

ZITIERVORSCHLAG (ORIGINALFASSUNG)

Pazer, S., Whitcombe, E. M., & Ashford, S. R. (2026). Evaluating AI-Based Psychological Interventions: Designs, control conditions, outcomes, safety monitoring and reporting standards. Journal of Meaning-Centered Psychology, 1(3), 48–51.

LIZENZ, KORRESPONDENZ UND EINSATZ VON KI

Erscheint im offenen Zugang unter der Lizenz Creative Commons Namensnennung 4.0 International (CC BY 4.0). Korrespondenz: Redaktion der Zeitschrift. Dieser Beitrag wurde mit Unterstützung generativer KI verfasst und von den Autorinnen und Autoren geprüft, die die volle Verantwortung für den Inhalt tragen.