Zeitschrift für Sinnzentrierte Psychologie
HERAUSGEGEBEN VOM INSTITUT FÜR SINNZENTRIERTE PSYCHOLOGIE

Jahrgang 1 · Heft 3 · Oktober 2026
S. 52–55 (Original) · Open Access · CC BY 4.0

ÜBERSICHTSARBEIT

Maschinelles Lernen zur Vorhersage in Psychotherapie und Psychiatrie

Eine narrative Übersicht zur Vorhersage von Therapieansprechen, Therapieabbruch und Suizidrisiko

Samuel R. Ashford, Eleanor M. Whitcombe und Sora Pazer
Institut für Sinnzentrierte Psychologie

Deutsche Übersetzung. Maßgeblich ist die englische Originalfassung.

ZUSAMMENFASSUNG

Maschinelles Lernen verspricht, die klinische Vorhersage in der psychischen Gesundheitsversorgung zu verbessern, indem es komplexe Muster in großen Datensätzen erkennt. Diese narrative Übersicht untersucht drei Bereiche, in denen solche Vorhersagen intensiv erforscht wurden: das Ansprechen auf Behandlung und die Auswahl von Behandlungen für einzelne Patientinnen und Patienten, den Abbruch von Psychotherapie sowie das Suizidrisiko. Studien aus allen drei Bereichen berichten, dass Modelle besser als der Zufall und in manchen Fällen besser als konventionelle Regressionsansätze diskriminieren können. Mehrere Einschränkungen begrenzen jedoch den klinischen Wert dieser Befunde. Viele Modelle wurden innerhalb einzelner Datensätze entwickelt und geprüft, und externe Validierungen haben gezeigt, dass sich die scheinbare Genauigkeit nicht auf neue Studien, Versorgungskontexte oder Populationen übertragen lassen muss. Bei seltenen Ereignissen wie dem Suizid ergeben selbst Modelle mit guter Diskriminationsfähigkeit sehr niedrige positive prädiktive Werte, sodass die meisten als hochgefährdet markierten Patientinnen und Patienten das Ereignis nicht erleben werden. Prospektive Studien, die zeigen, dass modellgestützte Entscheidungen die Behandlungsergebnisse verbessern, sind nach wie vor selten, und Algorithmen können Verzerrungen reproduzieren, die in ihren Trainingsdaten enthalten sind. Wir erörtern Berichts- und Bewertungsstandards wie TRIPOD und PROBAST, die Entscheidungskurvenanalyse sowie die Bedingungen, unter denen Vorhersageinstrumente das klinische Urteil und die therapeutische Begegnung unterstützen können, statt sie zu ersetzen.

Schlüsselwörter: maschinelles Lernen · klinische Vorhersagemodelle · Behandlungsauswahl · Suizidrisiko · positiver prädiktiver Wert

ABSTRACT

Machine learning promises to improve clinical prediction in mental health care by detecting complex patterns in large data sets. This narrative review examines three areas in which such predictions have been studied intensively: response to treatment and the selection of treatments for individual patients, dropout from psychotherapy, and suicide risk. Studies in all three areas report that models can discriminate better than chance, and in some cases better than conventional regression approaches. Several limitations, however, constrain the clinical value of these findings. Many models have been developed and tested within single data sets, and external validation has shown that apparent accuracy may not transfer to new trials, settings or populations. For rare outcomes such as suicide death, even models with good discrimination yield very low positive predictive values, so that most patients flagged as high risk will not experience the event. Prospective studies demonstrating that model-guided decisions improve outcomes remain scarce, and algorithms can reproduce biases embedded in their training data. We discuss reporting and appraisal standards such as TRIPOD and PROBAST, decision curve analysis, and the conditions under which prediction tools may support, rather than replace, clinical judgment and the therapeutic encounter.

Keywords: machine learning · clinical prediction models · treatment selection · suicide risk · positive predictive value

1 Einleitung

Klinisch Tätige treffen ständig Vorhersagen: ob eine Patientin oder ein Patient voraussichtlich von einer bestimmten Behandlung profitieren wird, ob eine Therapie vorzeitig beendet werden wird und ob eine Person in einer Krise unmittelbar gefährdet ist.

Maschinelles Lernen, verstanden im weiten Sinne als eine Familie von Verfahren, die prädiktive Zusammenhänge mit geringer Vorabspezifikation aus Daten lernen, hat die Hoffnung geweckt, solche Urteile genauer und individueller zu machen (Chekroud et al., 2021). Die Zunahme elektronischer Patientenakten, des routinemäßigen Outcome-Monitorings und großer Studiendatensätze hat diese Verfahren in Psychiatrie und Psychotherapie zunehmend praktikabel gemacht.

Diese narrative Übersicht fasst den Forschungsstand in drei Bereichen zusammen: Therapieansprechen und Behandlungsauswahl, Therapieabbruch sowie Suizidrisiko. Sie strebt keine erschöpfende Synthese an, sondern hebt repräsentative Studien und die methodischen Fragen hervor, von denen abhängt, ob ein Vorhersagemodell klinisch nützlich sein kann. Leitend ist die Unterscheidung zwischen statistischer Leistungsfähigkeit, die typischerweise als Diskrimination und Kalibrierung ausgedrückt wird, und klinischem Nutzen, also der Frage, ob die Verwendung eines Modells zu besseren Entscheidungen und Ergebnissen führt als sein Verzicht (Fusar-Poli et al., 2018; Steyerberg, 2019).

2 Therapieansprechen und Behandlungsauswahl

Die Forschung zur Behandlungsauswahl fragt, welche von mehreren verfügbaren Behandlungen für eine bestimmte Person am aussichtsreichsten ist. Cohen und DeRubeis (2018) gaben einen Überblick über Ansätze in der Depressionsbehandlung, die mehrere Patientenmerkmale zu individualisierten Empfehlungen verbinden, und betonten, dass solche Ansätze an Stichproben geprüft werden müssen, die von den zu ihrer Entwicklung verwendeten unabhängig sind. Ein einflussreiches frühes Beispiel nutzte Daten aus einer großen pharmakologischen Studie, um eine Remission unter Citalopram vorherzusagen, und prüfte das Modell in einer unabhängigen Studie (Chekroud et al., 2016). Die Genauigkeit lag in der externen Stichprobe für einige Behandlungsarme berichtetermaßen geringfügig über dem Zufallsniveau, für einen anderen jedoch nicht – ein Muster, das bereits sowohl das Potenzial als auch die Grenzen des Ansatzes veranschaulichte.

Spätere Arbeiten haben diese Grenzen deutlicher gemacht. Chekroud et al. (2024) untersuchten Modelle zur Vorhersage von Behandlungsergebnissen über mehrere unabhängige klinische Studien zu antipsychotischer Medikation bei Schizophrenie hinweg. Die Modelle schnitten innerhalb der Studie, in der sie entwickelt worden waren, gut ab, nach Angaben der Autoren jedoch nicht besser als der Zufall, wenn sie auf andere Studien angewendet wurden, und auch das Zusammenführen von Daten mehrerer Studien löste das Problem nicht. Die Autoren bezeichneten dies als illusorische Generalisierbarkeit. Obwohl diese Befunde die pharmakologische Behandlung betreffen, sind sie unmittelbar für die Psychotherapie relevant, in der Stichproben oft kleiner und Behandlungen weniger standardisiert sind. Sie legen zudem nahe, dass eine interne Kreuzvalidierung, so sorgfältig sie auch durchgeführt wird, die Prüfung an tatsächlich unabhängigen Stichproben nicht ersetzen kann.

Der entscheidende Test für die Behandlungsauswahl ist prospektiv. Lutz et al. (2022) randomisierten Therapeut-Patient-Dyaden in einer verhaltenstherapeutischen Hochschulambulanz entweder auf ein digitales Entscheidungsunterstützungssystem oder auf die Standardbehandlung. Sie berichteten bessere Ergebnisse, wenn Therapeutinnen und Therapeuten in den frühen Sitzungen der empfohlenen Strategie folgten, aber keinen Haupteffekt der Feedbackkomponente, und sie betonten, dass der Nutzen von der Qualität der Implementierung abhing. Solche Studien zeigen, dass der Wert eines Modells nicht allein in seiner Genauigkeit liegt, sondern in der Art seiner Verwendung.

3 Vorhersage von Therapieabbrüchen

Vorzeitige Therapiebeendigungen sind in der Psychotherapie häufig und gehen mit schlechteren Ergebnissen einher, was sie zu einem naheliegenden Ziel der Vorhersage macht. In einer großen naturalistischen Stichprobe ambulanter Patientinnen und Patienten in kognitiver Verhaltenstherapie verglichen Bennemann et al. (2022) eine Reihe von Algorithmen mittels verschachtelter Kreuzvalidierung und berichteten, dass ein Ensemble aus baumbasierten und Nächste-Nachbarn-Verfahren Abbrüche besser identifizierte als ein konventionelles verallgemeinertes lineares Modell. Zugleich blieb die Vorhersagegenauigkeit insgesamt moderat, und die Autorinnen und Autoren merkten an, dass sich nicht alle Algorithmen für naturalistische Daten und binäre Ereignisse eigneten.

Daraus folgen zwei Schlussfolgerungen. Erstens sind komplexere Algorithmen nicht automatisch überlegen; ihr Vorteil hängt von der Datenstruktur und der Stichprobengröße ab, und einfachere Modelle sollten stets als Vergleichsmaßstab berichtet werden.

Zweitens ist eine Abbruchvorhersage nur dann nützlich, wenn sie mit einer Intervention verbunden ist, deren Wirkung ihrerseits evaluiert werden kann, etwa einer erneuten Aufmerksamkeit für die therapeutische Beziehung oder einer gemeinsamen Überprüfung der Ziele der Patientin oder des Patienten. Einen Abbruch vorherzusagen, ohne etwas zu verändern, dokumentiert ihn lediglich im Voraus. Da Therapieabbruch in den Studien uneinheitlich definiert wird, etwa über die Sitzungszahl oder über das Urteil der Therapeutin oder des Therapeuten, sollte die Definition des Outcomes selbst berichtet und begründet werden.

4 Suizidrisiko und das Problem der Basisraten

Die Vorhersage des Suizidrisikos ist der Bereich, in dem die Kluft zwischen statistischer Leistungsfähigkeit und klinischem Nutzen am deutlichsten sichtbar wird. Eine Metaanalyse über fünf Jahrzehnte Forschung ergab, dass etablierte Risikofaktoren suizidale Gedanken und Verhaltensweisen nur geringfügig besser als der Zufall vorhersagten (Franklin et al., 2017), was die Hoffnung nährte, maschinelles Lernen auf großen Datensätzen könne mehr leisten. Modelle auf der Grundlage elektronischer Patientenakten haben tatsächlich eine hohe Diskrimination berichtet; in einer Studie über mehrere große Gesundheitssysteme hinweg fanden Simon et al. (2018), dass auf Konsultationen mit den höchsten Risikowerten ein erheblicher Anteil der nachfolgenden Suizidversuche und Suizide entfiel.

Die Diskrimination bestimmt jedoch nicht, wie viele der markierten Patientinnen und Patienten das Ereignis tatsächlich erleben werden. Diese Größe, der positive prädiktive Wert, hängt stark von der Basisrate ab. Ein hypothetisches Beispiel verdeutlicht dies: Bei einem Ereignis, das bei einer von 1.000 Personen auftritt, würde ein Test mit 90 % Sensitivität und 90 % Spezifität etwa 100 Personen markieren, von denen ungefähr eine das Ereignis erleben würde. Im Einklang mit dieser Logik berichtete eine systematische Übersichtsarbeit zu Suizidvorhersagemodellen gute globale Klassifikationsmaße, aber sehr niedrige positive prädiktive Werte, insbesondere für den Suizid (Belsher et al., 2019). Selbst in der Studie von Simon et al. (2018) unternahm die große Mehrheit der Patientinnen und Patienten in der höchsten Risikogruppe im Beobachtungszeitraum keinen Suizidversuch.

Das macht solche Modelle nicht wertlos. Ein niedriger positiver prädiktiver Wert kann akzeptabel sein, wenn die daraus folgende Maßnahme mit geringen Kosten und geringem Schaden verbunden ist, etwa ein strukturiertes Gespräch über Sicherheit, und inakzeptabel, wenn sie Zwangsmaßnahmen auslöst. Die Entscheidungskurvenanalyse bietet eine Möglichkeit, Nutzen und Schaden über eine Spanne von Entscheidungsschwellen hinweg abzuwägen (Vickers & Elkin, 2006). Die ethische Frage lautet daher nicht nur, wie genau ein Modell ist, sondern was aus seiner Ausgabe für die betroffene Person folgt.

5 Generalisierbarkeit, Verzerrung und klinischer Nutzen

In allen drei Bereichen ist die häufigste Schwäche eine unzureichende Validierung. Modelle, die innerhalb eines Datensatzes entwickelt und evaluiert werden, neigen dazu, ihre Leistungsfähigkeit zu überschätzen, insbesondere wenn die Zahl der Kandidatenprädiktoren im Verhältnis zur Zahl der Ereignisse groß ist. Berichtsleitlinien wie TRIPOD (Collins et al., 2015) und Bewertungsinstrumente wie PROBAST (Wolff et al., 2019) legen fest, was Leserinnen und Leser wissen müssen: wie die Teilnehmenden ausgewählt, wie Prädiktoren und Outcomes definiert und wie fehlende Daten behandelt wurden und ob eine interne und externe Validierung erfolgte. Die Kalibrierung, also die Übereinstimmung zwischen vorhergesagten und beobachteten Risiken, verdient ebenso viel Aufmerksamkeit wie die Diskrimination, weil schlecht kalibrierte Risikoschätzungen Entscheidungen selbst dann fehlleiten können, wenn die Rangfolge der Patientinnen und Patienten zutreffend ist (Steyerberg, 2019).

Generalisierbarkeit hat auch eine soziale Dimension. Obermeyer et al. (2019) zeigten, dass ein weit verbreiteter Algorithmus der Gesundheitsversorgung, der Kosten als Stellvertreter für den Versorgungsbedarf verwendete, den Bedarf Schwarzer Patientinnen und Patienten systematisch unterschätzte. Vergleichbare Risiken bestehen in der psychischen Gesundheitsversorgung, in der sich Zugang zur Behandlung, diagnostische Praxis und Dokumentation zwischen Gruppen unterscheiden. Modelle sollten daher hinsichtlich ihrer Leistungsfähigkeit in relevanten Untergruppen evaluiert und die Wahl der Zielvariable kritisch geprüft werden. Schließlich erfordert klinischer Nutzen prospektive Evidenz, idealerweise aus randomisierten Vergleichen einer Versorgung mit und ohne Modell, sowie Aufmerksamkeit dafür, wie klinisch Tätige sowie Patientinnen und Patienten Vorhersagen verstehen und auf sie reagieren

(Chekroud et al., 2021; Fusar-Poli et al., 2018). Wo Vorhersagen Patientinnen und Patienten mitgeteilt werden, sollten ihre Bedeutung und ihre Unsicherheit verständlich erklärt werden.

6 Fazit

Maschinelles Lernen hat in Psychotherapie und Psychiatrie eine umfangreiche Vorhersageforschung hervorgebracht, und einige Modelle diskriminieren besser als der Zufall oder besser als konventionelle Ansätze. Die Evidenz dafür, dass ihr Einsatz die Behandlungsergebnisse verbessert, bleibt jedoch begrenzt, ihre Leistungsfähigkeit lässt sich oft nicht verallgemeinern, und bei seltenen Ereignissen ist ihr positiver prädiktiver Wert zwangsläufig niedrig. Fortschritt hängt weniger von leistungsfähigeren Algorithmen ab als von sorgfältiger Validierung, transparenter Berichterstattung, Aufmerksamkeit für Fairness und prospektiver Evaluation des klinischen Nutzens. Für die Psychotherapieforschung bedeutet dies eine engere Zusammenarbeit zwischen klinisch Tätigen, Methodikerinnen und Methodikern sowie Datenwissenschaftlerinnen und Datenwissenschaftlern.

Aus sinnzentrierter Perspektive gilt ein weiterer Vorbehalt. Frankl betonte, dass der Mensch nie vollständig durch Bedingungen bestimmt ist, sondern die Freiheit behält, zu ihnen Stellung zu nehmen (Frankl, 1969). Ein Risikowert beschreibt eine statistische Tendenz in einer Population; er entscheidet nicht darüber, was ein einzelner Mensch aus seiner Situation macht. Vorhersageinstrumente können die klinische Aufmerksamkeit schärfen, sie sollten aber im Dienst der Begegnung zwischen Patientin oder Patient und Therapeutin oder Therapeut bleiben, statt an deren Stelle zu treten.

Literatur

Belsher, B. E., Smolenski, D. J., Pruitt, L. D., Bush, N. E., Beech, E. H., Workman, D. E., Morgan, R. L., Evatt, D. P., Tucker, J., & Skopp, N. A. (2019). Prediction models for suicide attempts and deaths: A systematic review and simulation. JAMA Psychiatry, 76(6), 642–651. https://doi.org/10.1001/jamapsychiatry.2019.0174

Bennemann, B., Schwartz, B., Giesemann, J., & Lutz, W. (2022). Predicting patients who will drop out of out-patient psychotherapy using machine learning algorithms. The British Journal of Psychiatry, 220(4), 192–201. https://doi.org/10.1192/bjp.2022.17

Chekroud, A. M., Bondar, J., Delgadillo, J., Doherty, G., Wasil, A., Fokkema, M., Cohen, Z., Belgrave, D., DeRubeis, R., Iniesta, R., Dwyer, D., & Choi, K. (2021). The promise of machine learning in predicting treatment outcomes in psychiatry. World Psychiatry, 20(2), 154–170. https://doi.org/10.1002/wps.20882

Chekroud, A. M., Hawrilenko, M., Loho, H., Bondar, J., Gueorguieva, R., Hasan, A., Kambeitz, J., Corlett, P. R., Koutsouleris, N., Krumholz, H. M., Krystal, J. H., & Paulus, M. (2024). Illusory generalizability of clinical prediction models. Science, 383(6679), 164–167. https://doi.org/10.1126/science.adg8538

Chekroud, A. M., Zotti, R. J., Shehzad, Z., Gueorguieva, R., Johnson, M. K., Trivedi, M. H., Cannon, T. D., Krystal, J. H., & Corlett, P. R. (2016). Cross-trial prediction of treatment outcome in depression: A machine learning approach. The Lancet Psychiatry, 3(3), 243–250. https://doi.org/10.1016/S2215-0366(15)00471-X

Cohen, Z. D., & DeRubeis, R. J. (2018). Treatment selection in depression. Annual Review of Clinical Psychology, 14, 209–236. https://doi.org/10.1146/annurev-clinpsy-050817-084746

Collins, G. S., Reitsma, J. B., Altman, D. G., & Moons, K. G. M. (2015). Transparent reporting of a multivariable prediction model for individual prognosis or diagnosis (TRIPOD): The TRIPOD statement. Annals of Internal Medicine, 162(1), 55–63. https://doi.org/10.7326/M14-0697

Frankl, V. E. (1969). The will to meaning: Foundations and applications of logotherapy. World Publishing.

Franklin, J. C., Ribeiro, J. D., Fox, K. R., Bentley, K. H., Kleiman, E. M., Huang, X., Musacchio, K. M., Jaroszewski, A. C., Chang, B. P., & Nock, M. K. (2017). Risk factors for suicidal thoughts and behaviors: A meta-analysis of 50 years of research. Psychological Bulletin, 143(2), 187–232. https://doi.org/10.1037/bul0000084

Fusar-Poli, P., Hijazi, Z., Stahl, D., & Steyerberg, E. W. (2018). The science of prognosis in psychiatry: A review. JAMA Psychiatry, 75(12), 1289–1297. https://doi.org/10.1001/jamapsychiatry.2018.2530

Lutz, W., Deisenhofer, A.-K., Rubel, J., Bennemann, B., Giesemann, J., Poster, K., & Schwartz, B. (2022). Prospective evaluation of a clinical decision support system in psychological therapy. Journal of Consulting and Clinical Psychology, 90(1), 90–106. https://doi.org/10.1037/ccp0000642

Obermeyer, Z., Powers, B., Vogeli, C., & Mullainathan, S. (2019). Dissecting racial bias in an algorithm used to manage the health of populations. Science, 366(6464), 447–453. https://doi.org/10.1126/science.aax2342

Simon, G. E., Johnson, E., Lawrence, J. M., Rossom, R. C., Ahmedani, B., Lynch, F. L., Beck, A., Waitzfelder, B., Ziebell, R., Penfold, R. B., & Shortreed, S. M. (2018). Predicting suicide attempts and suicide deaths following outpatient visits using electronic health records. American Journal of Psychiatry, 175(10), 951–960. https://doi.org/10.1176/appi.ajp.2018.17101167

Steyerberg, E. W. (2019). Clinical prediction models: A practical approach to development, validation, and updating (2nd ed.). Springer. https://doi.org/10.1007/978-3-030-16399-0

Vickers, A. J., & Elkin, E. B. (2006). Decision curve analysis: A novel method for evaluating prediction models. Medical Decision Making, 26(6), 565–574. https://doi.org/10.1177/0272989X06295361

Wolff, R. F., Moons, K. G. M., Riley, R. D., Whiting, P. F., Westwood, M., Collins, G. S., Reitsma, J. B., Kleijnen, J., & Mallett, S. (2019). PROBAST: A tool to assess the risk of bias and applicability of prediction model studies. Annals of Internal Medicine, 170(1), 51–58. https://doi.org/10.7326/M18-1376

ZITIERVORSCHLAG (ORIGINALFASSUNG)

Ashford, S. R., Whitcombe, E. M., & Pazer, S. (2026). Machine Learning for Prediction in Psychotherapy and Psychiatry: A narrative review of treatment response, dropout and suicide risk prediction. Journal of Meaning-Centered Psychology, 1(3), 52–55.

LIZENZ, KORRESPONDENZ UND EINSATZ VON KI

Erscheint im offenen Zugang unter der Lizenz Creative Commons Namensnennung 4.0 International (CC BY 4.0). Korrespondenz: Redaktion der Zeitschrift. Dieser Beitrag wurde mit Unterstützung generativer KI verfasst und von den Autorinnen und Autoren geprüft, die die volle Verantwortung für den Inhalt tragen.