Zeitschrift für Sinnzentrierte Psychologie
HERAUSGEGEBEN VOM INSTITUT FÜR SINNZENTRIERTE PSYCHOLOGIE

Jahrgang 1 · Heft 3 · Oktober 2026
S. 60–63 (Original) · Open Access · CC BY 4.0

ÜBERSICHTSARBEIT

Sprachverarbeitung von Psychotherapiesitzungen

Eine narrative Übersicht zu automatisierter Fidelitätskodierung, Empathieerkennung und Feedback an Therapeutinnen und Therapeuten

Eleanor M. Whitcombe, Sora Pazer und Samuel R. Ashford
Institut für Sinnzentrierte Psychologie

Deutsche Übersetzung. Maßgeblich ist die englische Originalfassung.

ZUSAMMENFASSUNG

Die Prozessforschung in der Psychotherapie war lange auf die menschliche Kodierung von Sitzungsaufnahmen angewiesen, ein reliables, aber arbeitsintensives Verfahren, das die Regelversorgung selten erreicht. Die Verarbeitung natürlicher Sprache (Natural Language Processing, NLP) eröffnet die Aussicht, therapeutische Gespräche in großem Umfang zu analysieren. Diese narrative Übersicht fasst die wichtigsten Forschungslinien zur automatisierten Analyse von Psychotherapiesitzungen zusammen. Zunächst beschreiben wir die automatisierte Kodierung der Fidelität in der motivierenden Gesprächsführung, von frühen Studien zur Textklassifikation bis zu automatisierten Verarbeitungsketten, die Spracherkennung, Sprecheridentifikation und Verhaltenskodierung verbinden. Anschließend referieren wir Arbeiten zur Empathieerkennung und zu weiteren Prozessvariablen wie der Arbeitsbeziehung und beschreiben Systeme, die Therapeutinnen und Therapeuten automatisch erzeugte Kennwerte zurückmelden oder während textbasierter Gespräche Vorschläge machen. Die Befunde deuten darauf hin, dass ausgewählte Verhaltensweisen von Therapeutinnen und Therapeuten mit vielversprechender Übereinstimmung mit menschlichen Ratern kodiert werden können, während relationale Konstrukte schwerer zu erfassen bleiben. Wir diskutieren Grenzen hinsichtlich der Validität, der Generalisierbarkeit über Settings und Sprachen, möglicher Reaktivität auf Kennzahlen und des Schutzes hochsensibler Sitzungsdaten. Aus sinnzentrierter Perspektive argumentieren wir, dass solche Werkzeuge reflektierte Praxis unterstützen können, aber weder das klinische Urteil noch die persönliche Begegnung im Zentrum der Psychotherapie ersetzen dürfen.

Schlüsselwörter: Verarbeitung natürlicher Sprache · motivierende Gesprächsführung · Behandlungsfidelität · Empathie · Psychotherapieprozessforschung

ABSTRACT

Process research in psychotherapy has long depended on human coding of session recordings, a reliable but labor-intensive procedure that rarely reaches routine care. Natural language processing (NLP) offers the prospect of analyzing therapeutic conversations at scale. This narrative review summarizes the main lines of research on the automated analysis of psychotherapy sessions. We first describe the automated coding of motivational interviewing fidelity, from early text classification studies to automated pipelines that combine speech recognition, speaker identification, and behavioral coding. We then review work on empathy detection and on other process variables such as the working alliance, and describe systems that return automatically generated metrics to therapists or offer suggestions during text-based conversations. The evidence suggests that selected therapist behaviors can be coded with promising agreement with human raters, whereas relational constructs remain more difficult to capture. We discuss limitations regarding validity, generalizability across settings and languages, possible reactivity to metrics, and the protection of highly sensitive session data. From a meaning-centered perspective, we argue that such tools can support reflective practice but must not replace clinical judgment or the personal encounter at the heart of psychotherapy.

Keywords: natural language processing · motivational interviewing · treatment fidelity · empathy · psychotherapy process research

1 Einleitung

Was im Therapieraum geschieht, ließ sich lange nur schwer in großem Umfang untersuchen. Prozessforschung ist auf Aufnahmen angewiesen, die geschulte Raterinnen und Rater nach Verhaltensmanualen kodieren, ein Verfahren, das bei

guter Durchführung reliabel, aber zeitaufwendig und kostspielig ist. Infolgedessen erhält die Regelversorgung selten systematische Rückmeldungen zur Qualität therapeutischer Gespräche, und die Prozessforschung bleibt auf vergleichsweise kleine Stichproben beschränkt (Atkins et al., 2014).

Die Verarbeitung natürlicher Sprache (Natural Language Processing, NLP), also die computergestützte Analyse gesprochener und geschriebener Sprache, verspricht, diese Situation zu verändern. Im vergangenen Jahrzehnt haben Forschungsgruppen Modelle entwickelt, die Sitzungen transkribieren, Sprechende identifizieren und einzelnen Äußerungen Verhaltenscodes zuordnen. Diese narrative Übersicht fasst die wichtigsten Linien dieser Forschung zusammen, mit Schwerpunkt auf der Fidelität in der motivierenden Gesprächsführung (Motivational Interviewing, MI), der Empathieerkennung und dem Feedback an Therapeutinnen und Therapeuten, und erörtert anschließend Fragen der Validität und des Datenschutzes, die beantwortet sein müssen, bevor solche Werkzeuge in die Routinepraxis gelangen. Die Übersicht ist selektiv und nicht systematisch; eine breitere Bestandsaufnahme des maschinellen Lernens in der Psychotherapieforschung bieten Aafjes-van Doorn et al. (2021).

2 Warum Prozesskodierung wichtig ist

Behandlungsfidelität, also das Ausmaß, in dem eine Therapeutin oder ein Therapeut eine Intervention wie vorgesehen und kompetent umsetzt, ist für Forschung und Ausbildung gleichermaßen zentral. Die metaanalytische Evidenz zum Zusammenhang zwischen Adhärenz oder Kompetenz und Behandlungsergebnis ist weniger konsistent als oft angenommen (Webb et al., 2010), doch die Überwachung der Fidelität bleibt unverzichtbar, um Studien zu interpretieren und sicherzustellen, dass das Verbreitete dem Geprüften entspricht. Die Empathie von Therapeutinnen und Therapeuten wiederum gehört zu den Beziehungsfaktoren, die am beständigsten mit dem Behandlungsergebnis zusammenhängen (Elliott et al., 2018).

MI bietet einen besonders geeigneten Testfall für die automatisierte Kodierung. Es handelt sich um einen gut spezifizierten, gesprächsbasierten Ansatz, in dem das verbale Verhalten der Therapeutin oder des Therapeuten, etwa offene Fragen, komplexe Reflexionen und Würdigungen, die Veränderungssprache der Klientin oder des Klienten prägen soll (Miller & Rollnick, 2013). Die Fidelität wird mit etablierten Kodiersystemen wie dem Motivational Interviewing Treatment Integrity Code erfasst, dessen aktuelle Version globale Einschätzungen mit Häufigkeitszählungen spezifischer Verhaltensweisen verbindet (Moyers et al., 2016). Die menschliche Kodierung mit solchen Instrumenten erfordert ein umfangreiches Training und erheblichen Zeitaufwand pro Sitzung, was ihren Einsatz in der Regelversorgung begrenzt.

3 Automatisierte Kodierung der Fidelität in der motivierenden Gesprächsführung

Atkins et al. (2014) zeigten früh, dass statistische Textklassifikation menschliche MI-Codes annähernd abbilden kann. Anhand von Transkripten von Beratungssitzungen trainierten sie Topic-Modelle zur Vorhersage von Codes auf Äußerungsebene und von Einschätzungen auf Sitzungsebene und berichteten, dass die Modelle die menschliche Kodierung für mehrere, wenn auch nicht alle Codes recht gut reproduzierten. Tanana et al. (2016) verglichen anschließend verschiedene NLP-Methoden zur Kodierung von MI-Äußerungen und fanden, dass die Übereinstimmung mit menschlichen Kodiererinnen und Kodierern zwischen den Codes erheblich variierte, wobei manche Verhaltensweisen zuverlässiger erkannt wurden als andere.

Spätere Arbeiten gingen von manuell erstellten Transkripten zu automatisierten Verarbeitungsketten über. Flemotomos et al. (2022) beschrieben ein System, das Audioaufnahmen über Sprachaktivitätserkennung, Sprechersegmentierung, automatische Spracherkennung und Rollenidentifikation verarbeitet, bevor es Verhaltenscodes zuweist und Qualitätsindikatoren auf Sitzungsebene schätzt. Angewandt auf Aufnahmen aus einem realen Beratungssetting ermöglicht eine solche Verarbeitungskette grundsätzlich, eine große Zahl von Sitzungen ohne menschliche Transkription auszuwerten. Mehrstufige Verarbeitungsketten werfen zudem ein spezifisches Problem auf: Fehler können sich über die Stufen fortpflanzen, sodass Ungenauigkeiten in der Spracherkennung oder der Sprecherzuordnung die resultierenden Codes beeinflussen können.

Zusammengenommen deuten diese Studien darauf hin, dass automatisierte MI-Kodierung machbar ist und dass die Übereinstimmung mit menschlichen Ratern für manche Codes und Indikatoren auf Sitzungsebene an die Interrater-Reliabilität menschlicher Kodierender heranreichen kann.

Zugleich ist die Leistungsfähigkeit uneinheitlich, und die meisten Modelle wurden in einer begrenzten Zahl von Datensätzen, Settings und Sprachen, überwiegend Englisch, entwickelt und getestet. Ob Modelle, die in einem Kontext trainiert wurden, auf andere Populationen, Behandlungsansätze und Sprachen generalisieren, ist weitgehend offen.

4 Empathieerkennung und weitere Prozessvariablen

Empathie lässt sich schwerer operationalisieren als spezifische MI-Verhaltensweisen, weil sie von der Bedeutung einer Äußerung im Kontext abhängt und nicht allein von Oberflächenmerkmalen. Xiao et al. (2015) zeigten dennoch, dass fremdeingeschätzte Empathie von Therapeutinnen und Therapeuten in Suchtberatungssitzungen aus Sprach- und Sprechmerkmalen in einem Maße vorhergesagt werden konnte, das praktisches Potenzial nahelegte. Für textbasierte Peer-Unterstützung schlugen Sharma et al. (2020) ein Rahmenmodell vor, das emotionale Reaktionen, Interpretationen und Explorationen als Kommunikationsmechanismen der Empathie unterscheidet, und entwickelten Modelle, um diese in Online-Gesprächen zu identifizieren.

Über Empathie hinaus wurden NLP-Methoden auf weitere Prozesskonstrukte angewandt. Goldberg et al. (2020) nutzten Sitzungstranskripte zur Vorhersage der von Klientinnen und Klienten eingeschätzten Arbeitsbeziehung und fanden, dass die Modelle einen Teil der Varianz der Allianzeinschätzungen erfassten, wenngleich die Vorhersagegenauigkeit bescheiden war. Das Scoping Review von Aafjes-van Doorn et al. (2021) dokumentierte ein rasch wachsendes, aber methodisch heterogenes Feld mit häufig kleinen Stichproben und begrenzter externer Validierung.

Diese Befunde verdeutlichen eine grundlegende Spannung. Konstrukte wie Empathie und Arbeitsbeziehung sind relational und teilweise subjektiv; sie werden von Klientinnen und Klienten erlebt und von Beobachtenden erschlossen. Ein Modell, das Beobachtereinschätzungen aus Text vorhersagt, lernt die Regelmäßigkeiten einer bestimmten Kodiertradition, nicht Empathie als solche. Seine Ausgaben sollten daher als Schätzungen dafür interpretiert werden, wie geschulte Raterinnen und Rater ein Gespräch wahrscheinlich beurteilen würden, mit allen Annahmen, die dies einschließt.

5 Von der Messung zum Feedback

Das wichtigste praktische Versprechen automatisierter Kodierung liegt im Feedback. Imel et al. (2019) entwickelten einen Prototyp, der Beraterinnen und Beratern nach einer Sitzung automatisch erzeugte MI-Fidelitätskennwerte zurückmeldete, und untersuchten dessen gestalterische Machbarkeit; die Teilnehmenden bewerteten das Feedback überwiegend als verständlich und potenziell nützlich für ihre berufliche Entwicklung. Solche Systeme könnten leistungsbezogenes Feedback, das sonst vor allem in supervidierter Ausbildung verfügbar ist, kontinuierlich zugänglich machen.

Ein weiterer Schritt ist die Unterstützung in Echtzeit. Sharma et al. (2023) berichteten aus einer randomisierten Studie auf einer Online-Plattform für Peer-Unterstützung, dass ein KI-System, das Vorschläge zur empathischeren Formulierung von Antworten machte, die eingeschätzte Empathie der Gespräche erhöhte, insbesondere bei Unterstützenden, denen der Ausdruck von Empathie schwerfiel. Diese Studie betraf Peer-Unterstützende und nicht Psychotherapeutinnen und Psychotherapeuten, und Empathie wurde auf der Ebene schriftlicher Nachrichten erfasst, sodass ihre Implikationen für die klinische Praxis nicht überschätzt werden sollten. Sie veranschaulicht dennoch, dass die Grenze zwischen Messung und Intervention verschwimmt, sobald Modelle während eines Gesprächs Vorschläge machen.

6 Validität, Datenschutz und ethische Fragen

Mehrere Validitätsfragen müssen geklärt werden, bevor automatisierte Kodierung für folgenreiche Entscheidungen genutzt werden kann. Erstens ist die Übereinstimmung mit menschlichen Kodierenden ein notwendiges, aber kein hinreichendes Kriterium; menschliche Codes besitzen selbst eine begrenzte Reliabilität, und ein Modell, das sie reproduziert, reproduziert auch ihre Fehler und Verzerrungen. Zweitens wurde die prädiktive Validität, also die Frage, ob automatisierte Indikatoren mit dem Behandlungsergebnis zusammenhängen, bislang selten untersucht. Drittens muss die Leistungsfähigkeit über Klientengruppen, Dialekte und Sprachen hinweg geprüft werden, da Spracherkennung und Sprachmodelle bei Sprechenden, die in Trainingsdaten unterrepräsentiert sind, schlechter funktionieren können. Schließlich könnten Therapeutinnen und Therapeuten, würden Fidelitätswerte für Bewertung oder Vergütung herangezogen, ihr verbales Verhalten eher an der Kennzahl als an der Klientin oder dem Klienten ausrichten.

Der Datenschutz ist nicht weniger wichtig. Therapieaufnahmen enthalten hochsensible Gesundheitsinformationen über Klientinnen und Klienten und häufig auch über Dritte. In der Europäischen Union fallen solche Daten unter die besonderen Kategorien personenbezogener Daten, die durch die Datenschutz-Grundverordnung geschützt sind; diese verlangt eine gültige Rechtsgrundlage, Zweckbindung, Datenminimierung sowie geeignete technische und organisatorische Schutzmaßnahmen (Regulation (EU) 2016/679, 2016). Die Aufzeichnung von Sitzungen zur automatisierten Analyse erfordert eine ausdrückliche und informierte Einwilligung, sichere Speicherung und klare Regeln zu Aufbewahrung und Sekundärnutzung, etwa für das Training von Modellen. Lokale Verarbeitung und De-Identifizierung können diese Risiken verringern, aber nicht beseitigen, da der Inhalt eines Gesprächs selbst identifizierend sein kann.

Schließlich verändert das Aufkommen großer Sprachmodelle das Feld. Solche Modelle können mit wenig aufgabenspezifischem Training Zusammenfassungen, Feedback und Codes erzeugen, produzieren aber auch flüssigen Text, dessen Bezug zum tatsächlichen Gespräch nicht gewährleistet ist (Bender et al., 2021). Validierungsstandards, die für spezialisierte Kodiermodelle etabliert wurden, einschließlich des Vergleichs mit menschlichen Einschätzungen und der Transparenz über Fehlerraten, sollten für diese allgemeineren Systeme gleichermaßen gelten.

7 Fazit

Die Sprachverarbeitung von Psychotherapiesitzungen hat sich von Machbarkeitsstudien zu automatisierten Verarbeitungsketten und ersten Feedbacksystemen entwickelt. Die Befunde deuten darauf hin, dass ausgewählte Verhaltensweisen von Therapeutinnen und Therapeuten, insbesondere in MI, mit vielversprechender Genauigkeit automatisch kodiert werden können und dass automatisiertes Feedback in ersten Studien von Fachpersonen akzeptiert wird. Belege dafür, dass solches Feedback therapeutische Fertigkeiten und letztlich die Behandlungsergebnisse in der Regelversorgung verbessert, sind noch begrenzt.

Aus sinnzentrierter Perspektive verdienen diese Werkzeuge eine differenzierte Bewertung. Sie können Therapeutinnen und Therapeuten helfen, ihre eigenen Gesprächsgewohnheiten klarer wahrzunehmen, und so reflektierte Praxis unterstützen. Sie können jedoch nicht erfassen, was ein Gespräch für den Menschen bedeutet, der Hilfe sucht. Als Lerninstrumente unter Bedingungen informierter Einwilligung und strengen Datenschutzes eingesetzt, können automatisierte Analysen Ausbildung und Qualitätssicherung bereichern; als Ersatz für das klinische Urteil oder als Kontrollinstrumente eingesetzt, drohen sie die therapeutische Begegnung auf das Zählbare zu reduzieren.

Literatur

Aafjes-van Doorn, K., Kamsteeg, C., Bate, J., & Aafjes, M. (2021). A scoping review of machine learning in psychotherapy research. Psychotherapy Research, 31(1), 92–116. https://doi.org/10.1080/10503307.2020.1808729

Atkins, D. C., Steyvers, M., Imel, Z. E., & Smyth, P. (2014). Scaling up the evaluation of psychotherapy: Evaluating motivational interviewing fidelity via statistical text classification. Implementation Science, 9, 49. https://doi.org/10.1186/1748-5908-9-49

Bender, E. M., Gebru, T., McMillan-Major, A., & Shmitchell, S. (2021). On the dangers of stochastic parrots: Can language models be too big? In Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency (pp. 610–623). Association for Computing Machinery. https://doi.org/10.1145/3442188.3445922

Elliott, R., Bohart, A. C., Watson, J. C., & Murphy, D. (2018). Therapist empathy and client outcome: An updated meta-analysis. Psychotherapy, 55(4), 399–410. https://doi.org/10.1037/pst0000175

Flemotomos, N., Martinez, V. R., Chen, Z., Singla, K., Ardulov, V., Peri, R., Caperton, D. D., Gibson, J., Tanana, M. J., Georgiou, P., Van Epps, J., Lord, S. P., Hirsch, T., Imel, Z. E., Atkins, D. C., & Narayanan, S. (2022). Automated evaluation of psychotherapy skills using speech and language technologies. Behavior Research Methods, 54(2), 690–711. https://doi.org/10.3758/s13428-021-01623-4

Goldberg, S. B., Flemotomos, N., Martinez, V. R., Tanana, M. J., Kuo, P. B., Pace, B. T., Villatte, J. L., Georgiou, P. G., Van Epps, J., Imel, Z. E., Narayanan, S. S., & Atkins, D. C. (2020). Machine learning and natural language processing in psychotherapy research: Alliance as example use case. Journal of Counseling Psychology, 67(4), 438–448. https://doi.org/10.1037/cou0000382

Imel, Z. E., Pace, B. T., Soma, C. S., Tanana, M., Hirsch, T., Gibson, J., Georgiou, P., Narayanan, S., & Atkins, D. C. (2019). Design feasibility of an automated, machine-learning based feedback system for motivational interviewing. Psychotherapy, 56(2), 318–328. https://doi.org/10.1037/pst0000221

Miller, W. R., & Rollnick, S. (2013). Motivational interviewing: Helping people change (3rd ed.). Guilford Press.

Moyers, T. B., Rowell, L. N., Manuel, J. K., Ernst, D., & Houck, J. M. (2016). The Motivational Interviewing Treatment Integrity code (MITI 4): Rationale, preliminary reliability and validity. Journal of Substance Abuse Treatment, 65, 36–42. https://doi.org/10.1016/j.jsat.2016.01.001

Regulation (EU) 2016/679 of the European Parliament and of the Council of 27 April 2016 on the protection of natural persons with regard to the processing of personal data and on the free movement of such data, and repealing Directive 95/46/EC (General Data Protection Regulation). (2016). Official Journal of the European Union, L 119, 1–88.

Sharma, A., Lin, I. W., Miner, A. S., Atkins, D. C., & Althoff, T. (2023). Human–AI collaboration enables more empathic conversations in text-based peer-to-peer mental health support. Nature Machine Intelligence, 5(1), 46–57. https://doi.org/10.1038/s42256-022-00593-2

Sharma, A., Miner, A. S., Atkins, D. C., & Althoff, T. (2020). A computational approach to understanding empathy expressed in text-based mental health support. In Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (pp. 5263–5276). Association for Computational Linguistics. https://doi.org/10.18653/v1/2020.emnlp-main.425

Tanana, M., Hallgren, K. A., Imel, Z. E., Atkins, D. C., & Srikumar, V. (2016). A comparison of natural language processing methods for automated coding of motivational interviewing. Journal of Substance Abuse Treatment, 65, 43–50. https://doi.org/10.1016/j.jsat.2016.01.006

Webb, C. A., DeRubeis, R. J., & Barber, J. P. (2010). Therapist adherence/competence and treatment outcome: A meta-analytic review. Journal of Consulting and Clinical Psychology, 78(2), 200–211. https://doi.org/10.1037/a0018912

Xiao, B., Imel, Z. E., Georgiou, P. G., Atkins, D. C., & Narayanan, S. S. (2015). “Rate my therapist”: Automated detection of empathy in drug and alcohol counseling via speech and language processing. PLoS ONE, 10(12), e0143055. https://doi.org/10.1371/journal.pone.0143055

ZITIERVORSCHLAG (ORIGINALFASSUNG)

Whitcombe, E. M., Pazer, S., & Ashford, S. R. (2026). Natural Language Processing of Psychotherapy Sessions: A narrative review of automated fidelity coding, empathy detection, and feedback to therapists. Journal of Meaning-Centered Psychology, 1(3), 60–63.

LIZENZ, KORRESPONDENZ UND EINSATZ VON KI

Erscheint im offenen Zugang unter der Lizenz Creative Commons Namensnennung 4.0 International (CC BY 4.0). Korrespondenz: Redaktion der Zeitschrift. Dieser Beitrag wurde mit Unterstützung generativer KI verfasst und von den Autorinnen und Autoren geprüft, die die volle Verantwortung für den Inhalt tragen.