Revue de psychologie centrée sur le sens
PUBLIÉE PAR L'INSTITUT DE PSYCHOLOGIE CENTRÉE SUR LE SENS

Volume 1 · Numéro 3 · octobre 2026
p. 36–39 (Original) · Libre accès · CC BY 4.0

ARTICLE DE SYNTHÈSE

Agents conversationnels et chatbots en santé mentale

Une revue narrative des données, des systèmes à base de règles aux grands modèles de langage

Sora Pazer, Samuel R. Ashford et Eleanor M. Whitcombe
Institut de psychologie centrée sur le sens

Traduction française. La version originale anglaise fait foi.

RÉSUMÉ

Les agents conversationnels, souvent appelés chatbots, sont de plus en plus proposés comme soutien à bas seuil pour les personnes en détresse psychologique. Cette revue narrative synthétise le développement et les données empiriques relatives à ces systèmes, des premiers programmes à base de règles aux agents fondés sur de grands modèles de langage. Elle décrit d'abord le passage technique des dialogues scénarisés aux systèmes génératifs et ses conséquences pour la prévisibilité et la sécurité. Elle examine ensuite les premières études randomisées et observationnelles d'agents structurés tels que Woebot et Wysa, les revues systématiques et méta-analyses du domaine, ainsi que le premier essai contrôlé randomisé portant sur un chatbot thérapeutique entièrement génératif. Dans l'ensemble, les études disponibles suggèrent des réductions à court terme, faibles à modérées, des symptômes de dépression et de détresse, avec une acceptation généralement favorable de la part des utilisateurs. Toutefois, les données sont limitées par de petits échantillons, des durées de suivi courtes, une attrition élevée, des conditions de comparaison faibles telles que des listes d'attente ou des contrôles purement informatifs, des mesures de résultats hétérogènes et une implication fréquente des développeurs dans la recherche. La sécurité en situation de crise et les réponses erronées des modèles génératifs restent insuffisamment étudiées. La revue conclut que les agents conversationnels doivent être compris comme un complément prometteur mais non démontré aux soins humains, et elle identifie des priorités pour la recherche future.

Mots-clés : agents conversationnels · chatbots · santé mentale numérique · grands modèles de langage · revue narrative

ABSTRACT

Conversational agents, often called chatbots, are increasingly offered as low-threshold support for people with psychological distress. This narrative review summarizes the development and the empirical evidence of such systems, from early rule-based programs to agents built on large language models. It first describes the technical shift from scripted dialogues to generative systems and the consequences of this shift for predictability and safety. It then discusses early randomized and observational studies of structured agents such as Woebot and Wysa, systematic reviews and meta-analyses of the field, and the first randomized controlled trial of a fully generative therapy chatbot. Overall, the available studies suggest small to moderate short-term reductions in symptoms of depression and distress, together with generally favorable user acceptance. However, the evidence is limited by small samples, short follow-up periods, high attrition, weak comparison conditions such as waitlists or information-only controls, heterogeneous outcome measures, and frequent involvement of developers in the research. Safety in crisis situations and erroneous output from generative models remain insufficiently studied. The review concludes that conversational agents are best understood as a promising but unproven complement to human care, and it identifies priorities for future research.

Keywords: conversational agents · chatbots · digital mental health · large language models · narrative review

1 Introduction

Dans de nombreux pays, la demande d'aide psychologique dépasse l'offre de professionnels formés, et les délais d'attente pour une psychothérapie sont souvent longs. Les interventions numériques ont été proposées comme un moyen de réduire cet écart, et les traitements psychologiques délivrés par Internet, en particulier les programmes guidés de thérapie cognitivo-comportementale (TCC), reposent désormais sur une base de preuves substantielle (Andersson et al., 2019). Les agents conversationnels constituent un développement plus récent dans ce

domaine. Au lieu de présenter des modules à lire et à compléter, ils interagissent avec les utilisateurs par un dialogue en langage naturel, généralement sous forme écrite.

L'arrivée de systèmes fondés sur de grands modèles de langage a conféré au sujet une urgence nouvelle. Ces systèmes peuvent produire des réponses fluides et apparemment empathiques sur presque tous les sujets, et de nombreuses personnes utilisent des chatbots généralistes pour obtenir un soutien émotionnel, qu'ils aient ou non été conçus à cette fin. La question de savoir ce que l'on sait réellement des bénéfices et des risques des agents conversationnels en santé mentale revêt donc une importance pratique considérable.

Cette revue narrative synthétise les principales lignes de développement et les données disponibles. Elle ne vise ni une recherche systématique ni une synthèse quantitative, mais s'appuie sur des études primaires clés et des revues systématiques publiées afin d'esquisser l'état des connaissances, ses limites et les questions ouvertes pour la recherche et la pratique.

2 Des systèmes à base de règles aux grands modèles de langage

L'histoire des agents conversationnels en psychologie commence généralement avec ELIZA, un programme qui simulait un thérapeute centré sur la personne en reconnaissant des mots-clés et en transformant les énoncés de l'utilisateur en questions (Weizenbaum, 1966). Bien que son mécanisme fût simple, les utilisateurs lui attribuaient volontiers une compréhension, phénomène désigné plus tard sous le nom d'effet ELIZA.

Pendant longtemps, la plupart des chatbots en santé mentale ont suivi une logique à base de règles ou de récupération. Les dialogues étaient scénarisés par des cliniciens et des développeurs, les utilisateurs choisissaient souvent parmi des réponses prédéfinies, et le système sélectionnait les contenus, par exemple de la psychoéducation ou des exercices issus de la TCC, selon des règles de décision fixes. Certains systèmes utilisaient le traitement automatique du langage naturel pour classer les saisies en texte libre, mais le contenu des réponses restait largement prédéterminé (Laranjo et al., 2018 ; Vaidyam et al., 2019). Cette conception limite la flexibilité, mais rend le comportement du système prévisible et vérifiable.

Les agents génératifs fondés sur de grands modèles de langage fonctionnent différemment. Ils produisent chaque réponse à nouveau sur la base de régularités statistiques apprises à partir de très grandes quantités de textes. Cela permet des conversations ouvertes et individualisées, mais signifie aussi que le contenu d'une réponse donnée ne peut être entièrement spécifié à l'avance. Les modèles génératifs peuvent produire des affirmations plausibles mais incorrectes ou non étayées, souvent qualifiées d'hallucinations (Ji et al., 2023). Pour les applications cliniques, le passage de systèmes scénarisés à des systèmes génératifs implique donc un déplacement des questions centrales : de la question de savoir si un programme fixe est efficace vers celle de savoir comment le comportement d'un système flexible peut être encadré, surveillé et évalué (Stade et al., 2024).

3 Premiers essais et évaluations en conditions réelles

L'une des premières études les plus fréquemment citées est un essai contrôlé randomisé portant sur Woebot, un agent à base de règles délivrant des éléments de TCC à de jeunes adultes présentant des symptômes de dépression et d'anxiété (Fitzpatrick et al., 2017). Sur une période de deux semaines, les participants qui utilisaient l'agent ont rapporté une diminution plus importante des symptômes dépressifs que les participants d'une condition de contrôle purement informative, orientés vers un livre électronique d'auto-assistance. L'étude était de petite taille, de courte durée et menée par des chercheurs liés à l'entreprise développant l'outil, ce que les auteurs ont reconnu.

Wysa, un agent combinant des contenus scénarisés et une conversation en texte libre, a été évalué dans une étude à méthodes mixtes en conditions réelles (Inkster et al., 2018). Les utilisateurs présentant des symptômes dépressifs autodéclarés qui utilisaient l'application plus fréquemment ont montré en moyenne une amélioration plus importante que les utilisateurs moins engagés. En l'absence de groupe contrôle randomisé et l'intensité d'utilisation étant autosélectionnée, ces résultats ne peuvent être interprétés comme la preuve d'un effet causal. Des travaux ultérieurs sur Woebot ont rapporté que les utilisateurs évaluaient leur lien avec l'agent, sur une mesure de l'alliance de travail, à des niveaux comparables à ceux rapportés pour d'autres formes de thérapie, bien que ces résultats reposent eux aussi sur des données observationnelles du développeur (Darcy et al., 2021).

Des préoccupations de sécurité sont également apparues tôt. Une étude portant sur des assistants vocaux généralistes a montré que leurs réponses à des énoncés concernant des idées suicidaires, la dépression ou la violence interpersonnelle étaient incohérentes et souvent incomplètes (Miner et al.,

2016). Bien que ces assistants n'aient pas été conçus comme des outils de santé mentale, ces résultats illustraient la manière dont des utilisateurs peuvent se tourner vers des systèmes conversationnels dans des situations de crise auxquelles ces systèmes ne sont pas préparés.

4 Revues systématiques et méta-analyses

Les premières revues systématiques décrivaient un domaine hétérogène comptant peu d'essais contrôlés. Une revue des agents conversationnels dans le domaine de la santé a conclu que la plupart des études étaient quasi expérimentales ou observationnelles et que les preuves d'efficacité clinique étaient limitées (Laranjo et al., 2018). Une revue centrée sur la psychiatrie a constaté une satisfaction et un engagement élevés des utilisateurs dans plusieurs études, tout en soulignant le caractère préliminaire des données et la nécessité d'évaluations plus rigoureuses (Vaidyam et al., 2019).

Une méta-analyse des interventions par chatbot en santé mentale a rapporté certains indices d'amélioration de la dépression, de la détresse et du stress, mais a jugé les preuves globales faibles, en raison du petit nombre d'études, d'un risque de biais élevé et de résultats incohérents (Abd-Alrazaq et al., 2020). Peu d'études rendaient compte de la sécurité. Une revue systématique et méta-analyse ultérieure des agents conversationnels fondés sur l'IA a constaté des réductions des symptômes de dépression et de détresse psychologique, tandis que les effets sur le bien-être psychologique n'étaient pas statistiquement significatifs (Li et al., 2023). Les auteurs ont également exploré l'expérience des utilisateurs et suggéré que la qualité de l'interaction humain–IA et le contenu du dialogue pourraient être déterminants pour les résultats.

Prises ensemble, ces synthèses suggèrent que les agents conversationnels peuvent produire des améliorations symptomatiques à court terme, en particulier pour la dépression et la détresse, avec des effets qui paraissent faibles à modérés. Des revues plus larges de la psychiatrie numérique aboutissent à une appréciation similaire et avertissent que l'enthousiasme a souvent devancé les preuves (Torous et al., 2021).

5 Le premier essai randomisé d'un chatbot thérapeutique génératif

Une étape récente est le premier essai contrôlé randomisé portant sur un chatbot d'IA entièrement génératif conçu pour le traitement en santé mentale (Heinz et al., 2025). Le système, appelé Therabot, a été entraîné sur des dialogues sélectionnés par des experts et fondés sur des psychothérapies validées empiriquement. Des adultes présentant des symptômes cliniquement significatifs de trouble dépressif majeur, de trouble d'anxiété généralisée ou un risque élevé de troubles des conduites alimentaires ont été répartis au hasard entre plusieurs semaines d'accès au chatbot et une condition de contrôle sur liste d'attente.

Les auteurs ont rapporté des réductions de symptômes plus importantes dans le groupe d'intervention pour les trois domaines cliniques, ainsi qu'un engagement élevé. Les évaluations de l'alliance thérapeutique par les participants ont été décrites comme comparables à celles rapportées pour la psychothérapie ambulatoire. Des cliniciens surveillaient les conversations, et l'équipe intervenait en cas de préoccupations de sécurité ou de réponses inappropriées.

L'essai est important parce qu'il montre qu'un système génératif peut être évalué au moyen d'un plan randomisé. Son interprétation reste cependant limitée. La comparaison avec une liste d'attente ne permet pas de conclure quant à l'efficacité par rapport à des traitements actifs ou à des programmes numériques plus simples, la durée de suivi était courte, et la surveillance humaine étendue ainsi que la procédure d'entraînement spécifique signifient que les résultats ne peuvent être transposés aux chatbots généralistes utilisés sans supervision.

6 Limites méthodologiques et questions ouvertes

Plusieurs limites reviennent dans l'ensemble de la littérature. Les échantillons sont souvent petits et issus de populations de convenance telles que des étudiants ou des utilisateurs d'applications. Les durées de suivi sont courtes, de sorte que la persistance des effets demeure largement inconnue. L'attrition est fréquemment élevée et le traitement des données manquantes varie. Les conditions de comparaison sont le plus souvent des listes d'attente ou des contrôles purement informatifs, qui tendent à surestimer les effets par rapport à des alternatives actives. Les mesures de résultats sont hétérogènes, et de nombreuses études sont menées ou financées par les développeurs du produit concerné (Abd-Alrazaq et al., 2020 ; Li et al., 2023).

Pour les systèmes génératifs, des problèmes supplémentaires apparaissent. Les versions des modèles évoluent rapidement, ce qui rend la réplication difficile et signifie qu'un essai publié peut

ne plus décrire le système que les utilisateurs rencontrent réellement. Les réponses erronées ou nuisibles ne peuvent être exclues par conception (Ji et al., 2023), et la détection des crises ainsi que les parcours d'orientation sont rarement évalués de manière systématique. Les propositions de développement responsable recommandent donc une évaluation par étapes, des tests de sécurité jusqu'aux essais contrôlés, avec une implication continue de l'expertise clinique (Stade et al., 2024).

Enfin, on sait peu de choses des mécanismes par lesquels les agents conversationnels pourraient agir. La question de savoir si un lien perçu avec un agent contribue aux résultats de la même manière que l'alliance dans la psychothérapie humaine, et quel rôle jouent le sens, la responsabilité et la propre réflexion de l'utilisateur, exige un travail à la fois empirique et conceptuel.

7 Conclusion

Les données relatives aux agents conversationnels en santé mentale se sont considérablement accrues au cours de la dernière décennie. Les études d'agents à base de règles et les méta-analyses suggèrent des bénéfices modestes à court terme sur les symptômes de dépression et de détresse, et le premier essai d'un chatbot thérapeutique génératif a produit des résultats encourageants dans des conditions soigneusement contrôlées. Les preuves restent néanmoins limitées par des suivis courts, des comparateurs faibles, une attrition élevée et de possibles conflits d'intérêts, et les questions de sécurité sont loin d'être résolues.

Les agents conversationnels doivent donc être considérés comme un complément prometteur mais non démontré aux soins humains plutôt que comme un substitut. La recherche future devrait recourir à des conditions de comparaison actives, à des suivis plus longs, à une communication transparente des versions de modèles et des événements de sécurité, ainsi qu'à des évaluations indépendantes. Pour une psychologie centrée sur le sens, il importera également de se demander non seulement si les symptômes s'améliorent, mais aussi si de tels outils renforcent ou affaiblissent la capacité d'une personne à prendre position face à sa propre situation.

Références

Abd-Alrazaq, A. A., Rababeh, A., Alajlani, M., Bewick, B. M., & Househ, M. (2020). Effectiveness and safety of using chatbots to improve mental health: Systematic review and meta-analysis. Journal of Medical Internet Research, 22(7), e16021. https://doi.org/10.2196/16021

Andersson, G., Titov, N., Dear, B. F., Rozental, A., & Carlbring, P. (2019). Internet-delivered psychological treatments: From innovation to implementation. World Psychiatry, 18(1), 20–28. https://doi.org/10.1002/wps.20610

Darcy, A., Daniels, J., Salinger, D., Wicks, P., & Robinson, A. (2021). Evidence of human-level bonds established with a digital conversational agent: Cross-sectional, retrospective observational study. JMIR Formative Research, 5(5), e27868. https://doi.org/10.2196/27868

Fitzpatrick, K. K., Darcy, A., & Vierhile, M. (2017). Delivering cognitive behavior therapy to young adults with symptoms of depression and anxiety using a fully automated conversational agent (Woebot): A randomized controlled trial. JMIR Mental Health, 4(2), e19. https://doi.org/10.2196/mental.7785

Heinz, M. V., Mackin, D. M., Trudeau, B. M., Bhattacharya, S., Wang, Y., Banta, H. A., Jewett, A. D., Salzhauer, A. J., Griffin, T. Z., & Jacobson, N. C. (2025). Randomized trial of a generative AI chatbot for mental health treatment. NEJM AI, 2(4), AIoa2400802. https://doi.org/10.1056/AIoa2400802

Inkster, B., Sarda, S., & Subramanian, V. (2018). An empathy-driven, conversational artificial intelligence agent (Wysa) for digital mental well-being: Real-world data evaluation mixed-methods study. JMIR mHealth and uHealth, 6(11), e12106. https://doi.org/10.2196/12106

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of hallucination in natural language generation. ACM Computing Surveys, 55(12), Article 248. https://doi.org/10.1145/3571730

Laranjo, L., Dunn, A. G., Tong, H. L., Kocaballi, A. B., Chen, J., Bashir, R., Surian, D., Gallego, B., Magrabi, F., Lau, A. Y. S., & Coiera, E. (2018). Conversational agents in healthcare: A systematic review. Journal of the American Medical Informatics Association, 25(9), 1248–1258. https://doi.org/10.1093/jamia/ocy072

Li, H., Zhang, R., Lee, Y.-C., Kraut, R. E., & Mohr, D. C. (2023). Systematic review and meta-analysis of AI-based conversational agents for promoting mental health and well-being. npj Digital Medicine, 6, 236. https://doi.org/10.1038/s41746-023-00979-5

Miner, A. S., Milstein, A., Schueller, S., Hegde, R., Mangurian, C., & Linos, E. (2016). Smartphone-based conversational agents and responses to questions about mental health, interpersonal violence, and physical health. JAMA Internal Medicine, 176(5), 619–625. https://doi.org/10.1001/jamainternmed.2016.0400

Stade, E. C., Stirman, S. W., Ungar, L. H., Boland, C. L., Schwartz, H. A., Yaden, D. B., Sedoc, J., DeRubeis, R. J., Willer, R., & Eichstaedt, J. C. (2024). Large language models could change the future of behavioral healthcare: A proposal for responsible development and evaluation. npj Mental Health Research, 3, 12. https://doi.org/10.1038/s44184-024-00056-z

Torous, J., Bucci, S., Bell, I. H., Kessing, L. V., Faurholt-Jepsen, M., Whelan, P., Carvalho, A. F., Keshavan, M., Linardon, J., & Firth, J. (2021). The growing field of digital psychiatry: Current evidence and the future of apps, social media, chatbots, and virtual reality. World Psychiatry, 20(3), 318–335. https://doi.org/10.1002/wps.20883

Vaidyam, A. N., Wisniewski, H., Halamka, J. D., Kashavan, M. S., & Torous, J. B. (2019). Chatbots and conversational agents in mental health: A review of the psychiatric landscape. The Canadian Journal of Psychiatry, 64(7), 456–464. https://doi.org/10.1177/0706743719828977

Weizenbaum, J. (1966). ELIZA—A computer program for the study of natural language communication between man and machine. Communications of the ACM, 9(1), 36–45. https://doi.org/10.1145/365153.365168

CITATION (VERSION ORIGINALE)

Pazer, S., Ashford, S. R., & Whitcombe, E. M. (2026). Conversational Agents and Chatbots for Mental Health: A narrative review of the evidence from rule-based systems to large language models. Journal of Meaning-Centered Psychology, 1(3), 36–39.

LICENCE, CORRESPONDANCE ET UTILISATION DE L'IA

Publié en libre accès sous licence Creative Commons Attribution 4.0 International (CC BY 4.0). Correspondance : rédaction de la revue. Cet article a été rédigé avec l'aide de l'IA générative et relu par les auteurs, qui en assument l'entière responsabilité.