Revue de psychologie centrée sur le sens
PUBLIÉE PAR L'INSTITUT DE PSYCHOLOGIE CENTRÉE SUR LE SENS

Volume 1 · Numéro 3 · octobre 2026
p. 48–51 (Original) · Libre accès · CC BY 4.0

ARTICLE MÉTHODOLOGIQUE

L'évaluation des interventions psychologiques fondées sur l'IA

Plans d'étude, conditions de contrôle, critères de jugement, surveillance de la sécurité et normes de publication

Sora Pazer, Eleanor M. Whitcombe et Samuel R. Ashford
Institut de psychologie centrée sur le sens

Traduction française. La version originale anglaise fait foi.

RÉSUMÉ

Les agents conversationnels et d'autres outils fondés sur l'IA sont de plus en plus proposés comme interventions psychologiques, mais les méthodes employées pour les évaluer n'ont pas suivi le rythme de leur développement technique. Cette contribution méthodologique présente les principales décisions de conception qui déterminent si une étude portant sur une intervention fondée sur l'IA peut étayer des conclusions crédibles. Nous situons d'abord les questions d'évaluation le long d'un cycle de développement, des études de faisabilité et d'optimisation, y compris les plans factoriels, adaptatifs et micro-randomisés, jusqu'aux essais contrôlés randomisés confirmatoires. Nous examinons ensuite le choix des conditions de contrôle, en soutenant que les listes d'attente et les contrôles purement informatifs répondent à des questions plus étroites qu'on ne le suppose souvent et que des comparateurs appariés en attention ou actifs sont nécessaires pour revendiquer des bénéfices spécifiques. Le choix des critères de jugement devrait associer des mesures symptomatiques validées à des indicateurs du fonctionnement, de l'utilisation et de l'attrition, et le suivi devrait s'étendre au-delà de l'évaluation post-traitement immédiate. Les systèmes génératifs ajoutent des exigences propres : une surveillance prospective de la sécurité avec des événements indésirables définis à l'avance, des procédures de détection des réponses nuisibles ou erronées et la documentation de la version et de la configuration du modèle utilisées tout au long d'un essai. Les extensions SPIRIT-AI et CONSORT-AI fournissent un cadre de publication pour ces éléments. Nous concluons que la rigueur méthodologique est une condition préalable à toute utilisation clinique responsable de l'IA en psychothérapie, y compris dans les approches centrées sur le sens.

Mots-clés : intelligence artificielle · essais contrôlés randomisés · conditions de contrôle · surveillance de la sécurité · CONSORT-AI

ABSTRACT

Conversational agents and other AI-based tools are increasingly offered as psychological interventions, yet the methods used to evaluate them have not kept pace with their technical development. This methodological contribution outlines the main design decisions that determine whether a study of an AI-based intervention can support credible conclusions. We first locate evaluation questions along a development cycle, from feasibility and optimization studies, including factorial, adaptive and micro-randomized designs, to confirmatory randomized controlled trials. We then discuss the choice of control conditions, arguing that waitlist and information-only comparators answer narrower questions than is often assumed and that attention-matched or active comparators are needed for claims about specific benefits. Outcome selection should combine validated symptom measures with indicators of functioning, engagement and attrition, and follow-up should extend beyond the immediate post-treatment assessment. Generative systems add distinctive requirements: prospective safety monitoring with predefined adverse events, procedures for detecting harmful or inaccurate outputs, and documentation of the model version and configuration used throughout a trial. The SPIRIT-AI and CONSORT-AI extensions provide a reporting framework for these elements. We conclude that methodological rigor is a precondition for any responsible clinical use of AI in psychotherapy, including meaning-centered approaches.

Keywords: artificial intelligence · randomized controlled trials · control conditions · safety monitoring · CONSORT-AI

1 Introduction

En une décennie, les interventions psychologiques fondées sur l'IA sont passées d'agents conversationnels à base de règles, délivrant des contenus scénarisés issus de la thérapie cognitivo-comportementale (TCC), à des systèmes reposant sur de grands modèles de langage qui génèrent des réponses ouvertes (Abd-Alrazaq et al., 2020 ; Torous et al., 2021). Des essais randomisés précoces, comme l'évaluation de Woebot auprès de jeunes adultes (Fitzpatrick et al., 2017), et des essais plus récents portant sur des chatbots génératifs (Heinz et al., 2025) ont rapporté des évolutions symptomatiques encourageantes. Dans le même temps, des revues systématiques ont décrit à plusieurs reprises la base de données probantes comme hétérogène, de court terme et d'une qualité méthodologique limitée (Abd-Alrazaq et al., 2020).

Cet article ne passe pas en revue l'efficacité ; cette tâche est assumée ailleurs dans ce numéro. Son objectif est méthodologique : décrire les décisions relatives au plan d'étude, aux comparateurs, aux critères de jugement, à la surveillance de la sécurité et à la publication qui déterminent ce qu'une étude portant sur une intervention fondée sur l'IA peut montrer et ce qu'elle ne peut pas montrer. L'argumentation s'appuie sur des principes établis de la recherche en psychothérapie et sur les extensions de publication élaborées pour les essais d'interventions fondées sur l'IA (Cruz Rivera et al., 2020 ; Liu et al., 2020). La question directrice est modeste : que devrait savoir un lecteur sceptique mais équitable avant de se fier à un bénéfice rapporté ?

2 Adapter les plans d'étude au cycle de développement

Toute étude n'a pas à être un essai contrôlé randomisé (ECR) confirmatoire, mais toute étude devrait préciser à quelle question elle répond. Mohr et al. (2017) ont soutenu que la recherche en santé mentale numérique a souffert d'évaluer des produits qui évoluent plus vite que les essais ne peuvent être menés à terme, et de négliger les contextes de mise en œuvre dans lesquels les outils seront effectivement utilisés. Une réponse utile consiste à distinguer des phases : études de faisabilité et d'acceptabilité, études d'optimisation qui identifient les composantes actives, et essais confirmatoires qui testent une intervention fixée et précisément spécifiée par rapport à un comparateur approprié.

Pour la phase d'optimisation, la stratégie d'optimisation multiphase (MOST) et les essais randomisés séquentiels à affectations multiples (SMART) permettent d'examiner des composantes et des règles de décision adaptatives avant de s'engager sur un dispositif complet (Collins et al., 2007). Les essais micro-randomisés, dans lesquels des incitations ou des messages sont randomisés de manière répétée chez chaque participant, conviennent aux questions portant sur les effets momentanés d'actions spécifiques d'un chatbot, par exemple savoir si une incitation à la réflexion envoyée après le signalement d'une humeur basse est suivie d'un meilleur ajustement dans les heures qui suivent (Klasnja et al., 2015). De tels plans conviennent bien aux agents conversationnels, car les échanges individuels peuvent être enregistrés et variés de façon systématique. Leurs résultats éclairent toutefois la conception d'une intervention ; ils n'établissent pas à eux seuls son efficacité clinique.

3 Conditions de contrôle et comparateurs

Le choix du comparateur définit la question causale d'un essai. Mohr et al. (2009) ont montré, pour les interventions psychologiques en général, que les conditions de contrôle diffèrent dans la mesure où elles contrôlent les attentes, l'attention, le temps et le contact, et que ces différences façonnent l'ampleur et la signification des effets observés. Une liste d'attente, telle que celle utilisée dans l'essai d'un chatbot génératif rapporté par Heinz et al. (2025), permet de savoir si proposer l'intervention vaut mieux que ne rien proposer pendant une période limitée. Un contrôle purement informatif, comme dans le premier essai de Woebot (Fitzpatrick et al., 2017), ajoute une activité minimale crédible, mais ne reproduit pas le caractère interactif et conversationnel de l'intervention.

Affirmer qu'un agent conversationnel produit des effets thérapeutiques spécifiques exige donc des comparateurs plus exigeants. Les options comprennent des contrôles appariés en attention, par exemple un agent conversationnel qui dialogue avec les utilisateurs sans délivrer le contenu actif supposé ; des interventions numériques établies, telles que la TCC délivrée par internet, avec ou sans accompagnement ; et, lorsque la question est celle de la substitution, une prise en charge assurée par des humains. Chaque option implique des arbitrages en matière de faisabilité, d'insu et d'acceptabilité éthique. Comme les participants savent généralement s'ils interagissent avec un chatbot, les attentes devraient au moins être mesurées à l'inclusion, et la crédibilité de la condition de contrôle devrait être évaluée plutôt

que présumée. Les plans de non-infériorité, souvent invoqués dans ce contexte, exigent une marge définie à l'avance et un échantillon d'une puissance suffisante.

4 Critères de jugement, utilisation et suivi

Les critères de jugement principaux devraient être des mesures validées, cliniquement pertinentes et définies à l'avance, idéalement complétées par des évaluations du fonctionnement et de la qualité de vie. Pour les approches centrées sur le sens, des mesures du sens de la vie peuvent être ajoutées comme critères secondaires, à condition que leur inclusion soit justifiée théoriquement et non par leur simple disponibilité. Les critères recueillis uniquement au sein de l'application elle-même risquent de confondre mesure et intervention, car le même contexte conversationnel qui délivre l'intervention suscite aussi l'auto-évaluation. Lorsque des évaluations cliniques par des évaluateurs sont réalisables, ceux-ci devraient ignorer l'affectation des participants, et les procédures d'évaluation à distance devraient être décrites.

L'utilisation et l'attrition requièrent une attention particulière. Eysenbach (2005) a décrit une « loi de l'attrition » dans les essais de santé en ligne, et une revue méta-analytique des interventions délivrées par smartphone a rapporté des taux d'abandon substantiels dans les études incluses (Linardon & Fuller-Tyszkiewicz, 2020). Les analyses devraient suivre le principe de l'intention de traiter, traiter les données manquantes par des méthodes adaptées au mécanisme de données manquantes supposé et rendre compte en détail de l'utilisation, par exemple du nombre de séances, de messages et de jours actifs. L'utilisation ne devrait pas être considérée comme un indicateur de bénéfice : un usage intensif peut refléter l'utilité perçue, mais aussi une dépendance ou une détresse non résolue. Enfin, des durées de suivi de quelques semaines, encore fréquentes, ne permettent pas de savoir si les effets se maintiennent ; les plans d'étude devraient prévoir des évaluations plusieurs mois après la fin de la phase active.

5 Surveillance de la sécurité et événements indésirables

La recherche en psychothérapie reconnaît depuis longtemps que les interventions peuvent causer des préjudices, et les travaux de consensus sur les interventions par internet recommandent de définir, de surveiller et de rapporter systématiquement les effets négatifs (Rozental et al., 2014). Pour les interventions fondées sur l'IA, cette obligation devient plus concrète. Les protocoles d'essai devraient préciser quels événements sont considérés comme indésirables, par exemple une aggravation des symptômes, l'apparition d'idées suicidaires, des révélations de crise qui ne sont pas prises en charge de manière appropriée ou des réponses qui renforcent des comportements nuisibles, et décrire comment ces événements sont détectés, signalés à un niveau supérieur et documentés.

Les systèmes génératifs introduisent une source de risque supplémentaire : ils peuvent produire des contenus fluides mais inexacts ou inadaptés, phénomène discuté dans la littérature informatique sous le nom d'hallucination (Ji et al., 2023). La surveillance de la sécurité devrait donc associer les événements indésirables signalés par les participants à un examen structuré des transcriptions de conversations, par exemple des audits cliniques portant sur un échantillon aléatoire de conversations et sur toutes les conversations signalées par des classificateurs automatisés. Heinz et al. (2025) ont décrit une supervision humaine des réponses du chatbot pendant leur essai ; de telles procédures, ainsi que la fréquence à laquelle les examinateurs ont dû intervenir, ont leur place dans le rapport d'essai. Stade et al. (2024) ont proposé un développement et une évaluation par étapes des applications de grands modèles de langage dans les soins de santé comportementale, l'autonomie n'étant étendue qu'à mesure que s'accumulent les preuves de sécurité.

6 Gestion des versions du modèle, transparence et publication

Une intervention psychologique conventionnelle peut être décrite dans un manuel ; un système fondé sur un grand modèle de langage est défini par le modèle sous-jacent, sa version, l'invite système, les sources de récupération, les filtres de sécurité et les paramètres de décodage. Chacun de ces éléments peut changer au cours d'un essai, parfois hors du contrôle des investigateurs lorsqu'un modèle commercial est utilisé par l'intermédiaire d'une interface maintenue par un fournisseur. Les protocoles devraient donc figer ou documenter la configuration, consigner chaque modification avec sa date et prévoir des analyses de sensibilité pour les périodes correspondant à des versions différentes. Sans ces informations, le résultat d'un essai ne peut être attribué à une intervention reproductible. Les textes d'invite et les règles de sécurité font partie de l'intervention et devraient être rendus accessibles, au moins aux évaluateurs, au même titre que les manuels de traitement.

Les extensions SPIRIT-AI et CONSORT-AI abordent ces questions pour les protocoles et les rapports (Cruz Rivera et al., 2020 ; Liu et al., 2020). Elles demandent notamment aux investigateurs d'indiquer la version du système d'IA, de décrire comment les données d'entrée ont été obtenues et comment les entrées de mauvaise qualité ou indisponibles ont été traitées, de préciser l'interaction entre l'humain et l'IA ainsi que la sortie du système, et de rendre compte de toute analyse des erreurs de performance. Bien que ces extensions aient été élaborées en pensant aux applications diagnostiques et d'aide à la décision, leur logique se transpose aux interventions conversationnelles. Le préenregistrement, un protocole accessible au public et, lorsque cela est juridiquement et éthiquement possible, le partage d'échantillons de conversations anonymisés renforceraient encore la confiance.

7 Conclusion

L'évaluation des interventions psychologiques fondées sur l'IA n'exige pas une nouvelle épistémologie, mais elle exige d'appliquer avec un soin particulier des principes familiers. La question étudiée devrait correspondre au plan d'étude ; les comparateurs devraient être suffisamment solides pour étayer les affirmations formulées ; les critères de jugement devraient dépasser les symptômes et les premières semaines ; la sécurité devrait être surveillée de manière prospective et transparente ; et le système évalué devrait être documenté avec assez de précision pour pouvoir être identifié à nouveau. Aucune de ces exigences n'est exotique ; la plupart sont déjà la norme dans les essais de traitements psychologiques et pharmacologiques.

Dans une perspective centrée sur le sens, la rigueur méthodologique possède aussi une dimension éthique. Les personnes qui se tournent vers un outil numérique dans la détresse lui confient une part de leur liberté et de leur responsabilité, et elles ont le droit de savoir si l'aide qui leur est proposée a été évaluée honnêtement. Une évaluation rigoureuse n'est donc pas un obstacle à l'innovation, mais une condition de son usage responsable.

Références

Abd-Alrazaq, A. A., Rababeh, A., Alajlani, M., Bewick, B. M., & Househ, M. (2020). Effectiveness and safety of using chatbots to improve mental health: Systematic review and meta-analysis. Journal of Medical Internet Research, 22(7), e16021. https://doi.org/10.2196/16021

Collins, L. M., Murphy, S. A., & Strecher, V. (2007). The multiphase optimization strategy (MOST) and the sequential multiple assignment randomized trial (SMART): New methods for more potent eHealth interventions. American Journal of Preventive Medicine, 32(5 Suppl.), S112–S118. https://doi.org/10.1016/j.amepre.2007.01.022

Cruz Rivera, S., Liu, X., Chan, A.-W., Denniston, A. K., Calvert, M. J., & SPIRIT-AI and CONSORT-AI Working Group. (2020). Guidelines for clinical trial protocols for interventions involving artificial intelligence: The SPIRIT-AI extension. Nature Medicine, 26(9), 1351–1363. https://doi.org/10.1038/s41591-020-1037-7

Eysenbach, G. (2005). The law of attrition. Journal of Medical Internet Research, 7(1), e11. https://doi.org/10.2196/jmir.7.1.e11

Fitzpatrick, K. K., Darcy, A., & Vierhile, M. (2017). Delivering cognitive behavior therapy to young adults with symptoms of depression and anxiety using a fully automated conversational agent (Woebot): A randomized controlled trial. JMIR Mental Health, 4(2), e19. https://doi.org/10.2196/mental.7785

Heinz, M. V., Mackin, D. M., Trudeau, B. M., Bhattacharya, S., Wang, Y., Banta, H. A., Jewett, A. D., Salzhauer, A. J., Griffin, T. Z., & Jacobson, N. C. (2025). Randomized trial of a generative AI chatbot for mental health treatment. NEJM AI, 2(4). https://doi.org/10.1056/AIoa2400802

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of hallucination in natural language generation. ACM Computing Surveys, 55(12), Article 248. https://doi.org/10.1145/3571730

Klasnja, P., Hekler, E. B., Shiffman, S., Boruvka, A., Almirall, D., Tewari, A., & Murphy, S. A. (2015). Microrandomized trials: An experimental design for developing just-in-time adaptive interventions. Health Psychology, 34(Suppl.), 1220–1228. https://doi.org/10.1037/hea0000305

Linardon, J., & Fuller-Tyszkiewicz, M. (2020). Attrition and adherence in smartphone-delivered interventions for mental health problems: A systematic and meta-analytic review. Journal of Consulting and Clinical Psychology, 88(1), 1–13. https://doi.org/10.1037/ccp0000459

Liu, X., Cruz Rivera, S., Moher, D., Calvert, M. J., Denniston, A. K., & SPIRIT-AI and CONSORT-AI Working Group. (2020). Reporting guidelines for clinical trial reports for interventions involving artificial intelligence: The CONSORT-AI extension. Nature Medicine, 26(9), 1364–1374. https://doi.org/10.1038/s41591-020-1034-x

Mohr, D. C., Spring, B., Freedland, K. E., Beckner, V., Arean, P., Hollon, S. D., Ockene, J., & Kaplan, R. (2009). The selection and design of control conditions for randomized controlled trials of psychological interventions. Psychotherapy and Psychosomatics, 78(5), 275–284. https://doi.org/10.1159/000228248

Mohr, D. C., Weingardt, K. R., Reddy, M., & Schueller, S. M. (2017). Three problems with current digital mental health research . . . and three things we can do about them. Psychiatric Services, 68(5), 427–429. https://doi.org/10.1176/appi.ps.201600541

Rozental, A., Andersson, G., Boettcher, J., Ebert, D. D., Cuijpers, P., Knaevelsrud, C., Ljótsson, B., Kaldo, V., Titov, N., & Carlbring, P. (2014). Consensus statement on defining and measuring negative effects of Internet interventions. Internet Interventions, 1(1), 12–19. https://doi.org/10.1016/j.invent.2014.02.001

Stade, E. C., Stirman, S. W., Ungar, L. H., Boland, C. L., Schwartz, H. A., Yaden, D. B., Sedoc, J., DeRubeis, R. J., Willer, R., & Eichstaedt, J. C. (2024). Large language models could change the future of behavioral healthcare: A proposal for responsible development and evaluation. npj Mental Health Research, 3, 12. https://doi.org/10.1038/s44184-024-00056-z

Torous, J., Bucci, S., Bell, I. H., Kessing, L. V., Faurholt-Jepsen, M., Whelan, P., Carvalho, A. F., Keshavan, M., Linardon, J., & Firth, J. (2021). The growing field of digital psychiatry: Current evidence and the future of apps, social media, chatbots, and virtual reality. World Psychiatry, 20(3), 318–335. https://doi.org/10.1002/wps.20883

CITATION (VERSION ORIGINALE)

Pazer, S., Whitcombe, E. M., & Ashford, S. R. (2026). Evaluating AI-Based Psychological Interventions: Designs, control conditions, outcomes, safety monitoring and reporting standards. Journal of Meaning-Centered Psychology, 1(3), 48–51.

LICENCE, CORRESPONDANCE ET UTILISATION DE L'IA

Publié en libre accès sous licence Creative Commons Attribution 4.0 International (CC BY 4.0). Correspondance : rédaction de la revue. Cet article a été rédigé avec l'aide de l'IA générative et relu par les auteurs, qui en assument l'entière responsabilité.