Revue de psychologie centrée sur le sens
PUBLIÉE PAR L'INSTITUT DE PSYCHOLOGIE CENTRÉE SUR LE SENS

Volume 1 · Numéro 3 · octobre 2026
p. 52–55 (Original) · Libre accès · CC BY 4.0

ARTICLE DE SYNTHÈSE

L'apprentissage automatique au service de la prédiction en psychothérapie et en psychiatrie

Une revue narrative de la prédiction de la réponse au traitement, de l'abandon et du risque suicidaire

Samuel R. Ashford, Eleanor M. Whitcombe et Sora Pazer
Institut de psychologie centrée sur le sens

Traduction française. La version originale anglaise fait foi.

RÉSUMÉ

L'apprentissage automatique promet d'améliorer la prédiction clinique dans les soins de santé mentale en détectant des configurations complexes dans de grands ensembles de données. Cette revue narrative examine trois domaines dans lesquels de telles prédictions ont été étudiées de manière intensive : la réponse au traitement et le choix des traitements pour chaque patient, l'abandon de la psychothérapie et le risque suicidaire. Les études menées dans ces trois domaines rapportent que des modèles peuvent discriminer mieux que le hasard et, dans certains cas, mieux que les approches de régression conventionnelles. Plusieurs limites restreignent toutefois la valeur clinique de ces résultats. De nombreux modèles ont été développés et testés au sein d'un seul ensemble de données, et la validation externe a montré que la précision apparente peut ne pas se transposer à de nouveaux essais, contextes ou populations. Pour des événements rares comme le décès par suicide, même des modèles dotés d'une bonne discrimination produisent des valeurs prédictives positives très faibles, de sorte que la plupart des patients signalés comme à haut risque ne connaîtront pas l'événement. Les études prospectives démontrant que des décisions guidées par un modèle améliorent les résultats restent rares, et les algorithmes peuvent reproduire des biais inscrits dans leurs données d'entraînement. Nous discutons des normes de publication et d'évaluation telles que TRIPOD et PROBAST, de l'analyse de courbe de décision et des conditions dans lesquelles les outils de prédiction peuvent soutenir, plutôt que remplacer, le jugement clinique et la rencontre thérapeutique.

Mots-clés : apprentissage automatique · modèles de prédiction clinique · choix du traitement · risque suicidaire · valeur prédictive positive

ABSTRACT

Machine learning promises to improve clinical prediction in mental health care by detecting complex patterns in large data sets. This narrative review examines three areas in which such predictions have been studied intensively: response to treatment and the selection of treatments for individual patients, dropout from psychotherapy, and suicide risk. Studies in all three areas report that models can discriminate better than chance, and in some cases better than conventional regression approaches. Several limitations, however, constrain the clinical value of these findings. Many models have been developed and tested within single data sets, and external validation has shown that apparent accuracy may not transfer to new trials, settings or populations. For rare outcomes such as suicide death, even models with good discrimination yield very low positive predictive values, so that most patients flagged as high risk will not experience the event. Prospective studies demonstrating that model-guided decisions improve outcomes remain scarce, and algorithms can reproduce biases embedded in their training data. We discuss reporting and appraisal standards such as TRIPOD and PROBAST, decision curve analysis, and the conditions under which prediction tools may support, rather than replace, clinical judgment and the therapeutic encounter.

Keywords: machine learning · clinical prediction models · treatment selection · suicide risk · positive predictive value

1 Introduction

Les cliniciens formulent constamment des prédictions : un patient bénéficiera-t-il probablement d'un traitement donné, la thérapie sera-t-elle interrompue prématurément, une personne en crise est-elle exposée à un risque imminent ? L'apprentissage automatique, compris au sens large comme une famille de méthodes qui apprennent des relations

prédictives à partir des données avec peu de spécifications préalables, a fait naître l'espoir que de tels jugements puissent devenir plus précis et plus individualisés (Chekroud et al., 2021). L'essor des dossiers médicaux électroniques, du suivi systématique des résultats et des grands ensembles de données d'essais a rendu ces méthodes de plus en plus applicables en psychiatrie et en psychothérapie.

Cette revue narrative résume l'état de la recherche dans trois domaines : la réponse au traitement et le choix du traitement, l'abandon, et le risque suicidaire. Elle ne vise pas une synthèse exhaustive ; elle met plutôt en évidence des études représentatives et les questions méthodologiques qui déterminent si un modèle de prédiction peut être cliniquement utile. La distinction directrice oppose la performance statistique, généralement exprimée en termes de discrimination et de calibration, à l'utilité clinique, c'est-à-dire la question de savoir si l'utilisation d'un modèle conduit à de meilleures décisions et à de meilleurs résultats que son absence (Fusar-Poli et al., 2018 ; Steyerberg, 2019).

2 Réponse au traitement et choix du traitement

La recherche sur le choix du traitement se demande lequel de plusieurs traitements disponibles est le plus prometteur pour une personne donnée. Cohen et DeRubeis (2018) ont passé en revue des approches, dans le domaine de la dépression, qui combinent de multiples caractéristiques des patients en recommandations individualisées, et ont souligné que ces approches doivent être testées sur des échantillons indépendants de ceux qui ont servi à les construire. Un premier exemple influent a utilisé les données d'un vaste essai pharmacologique pour prédire la rémission sous citalopram et a testé le modèle dans un essai indépendant (Chekroud et al., 2016). La précision rapportée dans l'échantillon externe était légèrement supérieure au hasard pour certains bras de traitement, mais pas pour un autre, un schéma qui illustrait déjà à la fois les promesses et les limites de l'approche.

Des travaux ultérieurs ont précisé ces limites. Chekroud et al. (2024) ont examiné des modèles prédisant les résultats dans plusieurs essais cliniques indépendants de médicaments antipsychotiques dans la schizophrénie. Les modèles étaient performants au sein de l'essai dans lequel ils avaient été développés mais, selon les auteurs, ne faisaient pas mieux que le hasard lorsqu'ils étaient appliqués à d'autres essais, et le regroupement des données de plusieurs essais ne résolvait pas le problème. Les auteurs ont qualifié ce phénomène de généralisabilité illusoire. Bien que ces résultats concernent le traitement pharmacologique, ils intéressent directement la psychothérapie, où les échantillons sont souvent plus petits et les traitements moins standardisés. Ils suggèrent également que la validation croisée interne, aussi soigneusement menée soit-elle, ne peut remplacer un test sur des échantillons véritablement indépendants.

Le test décisif du choix du traitement est prospectif. Lutz et al. (2022) ont randomisé des dyades thérapeute-patient d'une consultation ambulatoire de thérapie cognitivo-comportementale (TCC) entre un système numérique d'aide à la décision et le traitement habituel. Ils ont rapporté de meilleurs résultats lorsque les thérapeutes suivaient la stratégie recommandée au cours des premières séances, mais aucun effet principal de la composante de rétroaction, et ils ont souligné que les bénéfices dépendaient de la qualité de la mise en œuvre. De telles études montrent que la valeur d'un modèle ne réside pas uniquement dans sa précision, mais dans la manière dont il est utilisé.

3 Prédire l'abandon

L'interruption prématurée est fréquente en psychothérapie et associée à de moins bons résultats, ce qui en fait une cible évidente pour la prédiction. Dans un vaste échantillon naturaliste de patients ambulatoires suivant une TCC, Bennemann et al. (2022) ont comparé un ensemble d'algorithmes au moyen d'une validation croisée imbriquée et ont rapporté qu'un ensemble combinant des méthodes fondées sur les arbres et sur les plus proches voisins identifiait l'abandon mieux qu'un modèle linéaire généralisé conventionnel. Dans le même temps, la précision prédictive globale restait modeste, et les auteurs ont noté que tous les algorithmes n'étaient pas adaptés aux données naturalistes et aux événements binaires.

Deux conclusions s'ensuivent. Premièrement, les algorithmes plus complexes ne sont pas automatiquement supérieurs ; leur avantage dépend de la structure des données et de la taille de l'échantillon, et des modèles plus simples devraient toujours être rapportés comme référence. Deuxièmement, une prédiction de l'abandon n'est utile que si elle est reliée à une intervention dont l'effet peut lui-même être évalué, par exemple une attention renouvelée à l'alliance thérapeutique ou un réexamen commun des objectifs du patient. Prédire l'abandon sans rien changer revient simplement à le documenter à l'avance. Comme l'abandon est défini de manière hétérogène selon les études, par exemple par le

nombre de séances ou par le jugement du thérapeute, la définition du critère elle-même devrait être rapportée et justifiée.

4 Risque suicidaire et problème des taux de base

La prédiction du risque suicidaire est le domaine où l'écart entre performance statistique et utilité clinique est le plus visible. Une méta-analyse couvrant cinq décennies de recherche a montré que les facteurs de risque établis ne prédisaient les pensées et comportements suicidaires que légèrement mieux que le hasard (Franklin et al., 2017), ce qui a nourri l'espoir que l'apprentissage automatique appliqué à de grands ensembles de données puisse faire mieux. Des modèles fondés sur les dossiers médicaux électroniques ont effectivement rapporté une discrimination élevée ; dans une étude menée dans plusieurs grands systèmes de santé, Simon et al. (2018) ont constaté que les consultations présentant les scores de risque les plus élevés représentaient une part substantielle des tentatives de suicide et des décès par suicide ultérieurs.

La discrimination ne détermine cependant pas combien de patients signalés connaîtront réellement l'événement. Cette grandeur, la valeur prédictive positive, dépend fortement du taux de base. Une illustration hypothétique le montre : pour un événement survenant chez un patient sur 1 000, un test d'une sensibilité de 90 % et d'une spécificité de 90 % signalerait environ 100 patients, dont à peu près un seul connaîtrait l'événement. Conformément à cette logique, une revue systématique des modèles de prédiction du suicide a rapporté de bons indicateurs globaux de classification, mais des valeurs prédictives positives très faibles, en particulier pour le décès par suicide (Belsher et al., 2019). Même dans l'étude de Simon et al. (2018), la grande majorité des patients de la strate de risque la plus élevée n'ont pas fait de tentative de suicide pendant la période de suivi.

Cela ne rend pas ces modèles sans valeur. Une faible valeur prédictive positive peut être acceptable si l'action qui en découle est peu coûteuse et peu nuisible, comme un entretien structuré sur la sécurité, et inacceptable si elle déclenche des mesures de contrainte. L'analyse de courbe de décision offre un moyen de mettre en balance bénéfices et préjudices sur une gamme de seuils de décision (Vickers & Elkin, 2006). La question éthique n'est donc pas seulement de savoir quelle est la précision d'un modèle, mais ce qui découle de ses résultats pour la personne concernée.

5 Généralisabilité, biais et utilité clinique

Dans les trois domaines, la faiblesse la plus fréquente est une validation insuffisante. Les modèles développés et évalués au sein d'un même ensemble de données tendent à surestimer leur performance, en particulier lorsque le nombre de prédicteurs candidats est élevé par rapport au nombre d'événements. Les lignes directrices de publication telles que TRIPOD (Collins et al., 2015) et les outils d'évaluation tels que PROBAST (Wolff et al., 2019) précisent ce que les lecteurs doivent savoir : comment les participants ont été sélectionnés, comment les prédicteurs et les critères de jugement ont été définis, comment les données manquantes ont été traitées et si une validation interne et externe a été réalisée. La calibration, c'est-à-dire l'accord entre risques prédits et risques observés, mérite autant d'attention que la discrimination, car des estimations de risque mal calibrées peuvent égarer les décisions même lorsque les patients sont correctement classés (Steyerberg, 2019).

La généralisabilité a aussi une dimension sociale. Obermeyer et al. (2019) ont montré qu'un algorithme de santé largement utilisé, qui employait les coûts comme indicateur indirect des besoins de santé, sous-estimait systématiquement les besoins des patients noirs. Des risques analogues existent dans les soins de santé mentale, où l'accès au traitement, les pratiques diagnostiques et la documentation diffèrent selon les groupes. Les modèles devraient donc être évalués quant à leur performance dans les sous-groupes pertinents, et le choix de la variable cible devrait être examiné de manière critique. Enfin, l'utilité clinique exige des preuves prospectives, idéalement issues de comparaisons randomisées entre des soins avec et sans modèle, ainsi qu'une attention à la manière dont cliniciens et patients comprennent les prédictions et agissent en conséquence (Chekroud et al., 2021 ; Fusar-Poli et al., 2018). Lorsque des prédictions sont communiquées aux patients, leur signification et leur incertitude devraient être expliquées en termes compréhensibles.

6 Conclusion

L'apprentissage automatique a produit un corpus important de recherches sur la prédiction en psychothérapie et en psychiatrie, et certains modèles discriminent mieux que le hasard ou mieux que les approches conventionnelles. Pourtant, les preuves que leur utilisation améliore les résultats restent limitées, leur performance se généralise souvent mal et, pour

les événements rares, leur valeur prédictive positive est nécessairement faible. Les progrès dépendent moins d'algorithmes plus puissants que d'une validation rigoureuse, d'une publication transparente, d'une attention à l'équité et d'une évaluation prospective de l'utilité clinique. Pour la recherche en psychothérapie, cela implique une collaboration plus étroite entre cliniciens, méthodologistes et spécialistes des données.

Dans une perspective centrée sur le sens, une réserve supplémentaire s'impose. Frankl a insisté sur le fait que la personne n'est jamais entièrement déterminée par les conditions, mais conserve la liberté de prendre position à leur égard (Frankl, 1969). Un score de risque décrit une tendance statistique dans une population ; il ne décide pas de ce qu'un individu fera de sa situation. Les outils de prédiction peuvent aiguiser l'attention clinique, mais ils devraient rester au service de la rencontre entre patient et thérapeute plutôt que de prendre sa place.

Références

Belsher, B. E., Smolenski, D. J., Pruitt, L. D., Bush, N. E., Beech, E. H., Workman, D. E., Morgan, R. L., Evatt, D. P., Tucker, J., & Skopp, N. A. (2019). Prediction models for suicide attempts and deaths: A systematic review and simulation. JAMA Psychiatry, 76(6), 642–651. https://doi.org/10.1001/jamapsychiatry.2019.0174

Bennemann, B., Schwartz, B., Giesemann, J., & Lutz, W. (2022). Predicting patients who will drop out of out-patient psychotherapy using machine learning algorithms. The British Journal of Psychiatry, 220(4), 192–201. https://doi.org/10.1192/bjp.2022.17

Chekroud, A. M., Bondar, J., Delgadillo, J., Doherty, G., Wasil, A., Fokkema, M., Cohen, Z., Belgrave, D., DeRubeis, R., Iniesta, R., Dwyer, D., & Choi, K. (2021). The promise of machine learning in predicting treatment outcomes in psychiatry. World Psychiatry, 20(2), 154–170. https://doi.org/10.1002/wps.20882

Chekroud, A. M., Hawrilenko, M., Loho, H., Bondar, J., Gueorguieva, R., Hasan, A., Kambeitz, J., Corlett, P. R., Koutsouleris, N., Krumholz, H. M., Krystal, J. H., & Paulus, M. (2024). Illusory generalizability of clinical prediction models. Science, 383(6679), 164–167. https://doi.org/10.1126/science.adg8538

Chekroud, A. M., Zotti, R. J., Shehzad, Z., Gueorguieva, R., Johnson, M. K., Trivedi, M. H., Cannon, T. D., Krystal, J. H., & Corlett, P. R. (2016). Cross-trial prediction of treatment outcome in depression: A machine learning approach. The Lancet Psychiatry, 3(3), 243–250. https://doi.org/10.1016/S2215-0366(15)00471-X

Cohen, Z. D., & DeRubeis, R. J. (2018). Treatment selection in depression. Annual Review of Clinical Psychology, 14, 209–236. https://doi.org/10.1146/annurev-clinpsy-050817-084746

Collins, G. S., Reitsma, J. B., Altman, D. G., & Moons, K. G. M. (2015). Transparent reporting of a multivariable prediction model for individual prognosis or diagnosis (TRIPOD): The TRIPOD statement. Annals of Internal Medicine, 162(1), 55–63. https://doi.org/10.7326/M14-0697

Frankl, V. E. (1969). The will to meaning: Foundations and applications of logotherapy. World Publishing.

Franklin, J. C., Ribeiro, J. D., Fox, K. R., Bentley, K. H., Kleiman, E. M., Huang, X., Musacchio, K. M., Jaroszewski, A. C., Chang, B. P., & Nock, M. K. (2017). Risk factors for suicidal thoughts and behaviors: A meta-analysis of 50 years of research. Psychological Bulletin, 143(2), 187–232. https://doi.org/10.1037/bul0000084

Fusar-Poli, P., Hijazi, Z., Stahl, D., & Steyerberg, E. W. (2018). The science of prognosis in psychiatry: A review. JAMA Psychiatry, 75(12), 1289–1297. https://doi.org/10.1001/jamapsychiatry.2018.2530

Lutz, W., Deisenhofer, A.-K., Rubel, J., Bennemann, B., Giesemann, J., Poster, K., & Schwartz, B. (2022). Prospective evaluation of a clinical decision support system in psychological therapy. Journal of Consulting and Clinical Psychology, 90(1), 90–106. https://doi.org/10.1037/ccp0000642

Obermeyer, Z., Powers, B., Vogeli, C., & Mullainathan, S. (2019). Dissecting racial bias in an algorithm used to manage the health of populations. Science, 366(6464), 447–453. https://doi.org/10.1126/science.aax2342

Simon, G. E., Johnson, E., Lawrence, J. M., Rossom, R. C., Ahmedani, B., Lynch, F. L., Beck, A., Waitzfelder, B., Ziebell, R., Penfold, R. B., & Shortreed, S. M. (2018). Predicting suicide attempts and suicide deaths following outpatient visits using electronic health records. American Journal of Psychiatry, 175(10), 951–960. https://doi.org/10.1176/appi.ajp.2018.17101167

Steyerberg, E. W. (2019). Clinical prediction models: A practical approach to development, validation, and updating (2nd ed.). Springer. https://doi.org/10.1007/978-3-030-16399-0

Vickers, A. J., & Elkin, E. B. (2006). Decision curve analysis: A novel method for evaluating prediction models. Medical Decision Making, 26(6), 565–574. https://doi.org/10.1177/0272989X06295361

Wolff, R. F., Moons, K. G. M., Riley, R. D., Whiting, P. F., Westwood, M., Collins, G. S., Reitsma, J. B., Kleijnen, J., & Mallett, S. (2019). PROBAST: A tool to assess the risk of bias and applicability of prediction model studies. Annals of Internal Medicine, 170(1), 51–58. https://doi.org/10.7326/M18-1376

CITATION (VERSION ORIGINALE)

Ashford, S. R., Whitcombe, E. M., & Pazer, S. (2026). Machine Learning for Prediction in Psychotherapy and Psychiatry: A narrative review of treatment response, dropout and suicide risk prediction. Journal of Meaning-Centered Psychology, 1(3), 52–55.

LICENCE, CORRESPONDANCE ET UTILISATION DE L'IA

Publié en libre accès sous licence Creative Commons Attribution 4.0 International (CC BY 4.0). Correspondance : rédaction de la revue. Cet article a été rédigé avec l'aide de l'IA générative et relu par les auteurs, qui en assument l'entière responsabilité.