Revue de psychologie centrée sur le sens
PUBLIÉE PAR L'INSTITUT DE PSYCHOLOGIE CENTRÉE SUR LE SENS

Volume 1 · Numéro 3 · octobre 2026
p. 56–59 (Original) · Libre accès · CC BY 4.0

ARTICLE THÉORIQUE

Éthique et régulation de l'intelligence artificielle en psychothérapie

Autonomie, responsabilité, protection des données et protection des utilisateurs vulnérables dans le droit européen émergent

Samuel R. Ashford, Sora Pazer et Eleanor M. Whitcombe
Institut de psychologie centrée sur le sens

Traduction française. La version originale anglaise fait foi.

RÉSUMÉ

L'intelligence artificielle (IA) fait son entrée en psychothérapie par le biais d'agents conversationnels, d'outils d'aide à la décision clinique et de la documentation automatisée. Ces applications soulèvent des questions éthiques d'une urgence particulière dans un domaine fondé sur la confiance, la confidentialité et la rencontre personnelle. Cette contribution théorique examine cinq domaines de préoccupation : le respect de l'autonomie du patient et le consentement éclairé, l'attribution de la responsabilité lorsque des systèmes algorithmiques contribuent aux décisions cliniques, la protection de données de santé mentale hautement sensibles ainsi que la transparence et le risque de biais systématiques, la protection des utilisateurs vulnérables en situation de crise, et la réponse réglementaire. En nous appuyant sur le principisme en éthique biomédicale et sur la littérature plus large consacrée à l'éthique des algorithmes, nous soutenons que l'évaluation éthique de l'IA en psychothérapie ne peut se réduire à la performance technique. Nous esquissons en termes généraux la manière dont le cadre européen, composé du règlement général sur la protection des données, du règlement relatif aux dispositifs médicaux et du règlement sur l'intelligence artificielle, répond à ces préoccupations et où subsistent des lacunes. Dans une perspective centrée sur le sens, nous soulignons que la responsabilité, catégorie centrale de la logothérapie de Frankl, ne peut être déléguée à une machine. Nous concluons par des principes pour la conception, l'évaluation et l'usage clinique responsables de l'IA en psychothérapie.

Mots-clés : intelligence artificielle · éthique de la psychothérapie · responsabilité · protection des données · règlement européen sur l'IA

ABSTRACT

Artificial intelligence (AI) is entering psychotherapy through conversational agents, clinical decision-support tools, and automated documentation. These applications raise ethical questions of particular urgency in a field built on trust, confidentiality, and personal encounter. This theoretical contribution examines five areas of concern: respect for patient autonomy and informed consent, the attribution of responsibility when algorithmic systems contribute to clinical decisions, the protection of highly sensitive mental health data together with transparency and the risk of systematic bias, the protection of vulnerable users in crisis situations, and the regulatory response. Drawing on principlism in biomedical ethics and on the broader literature on the ethics of algorithms, we argue that the ethical evaluation of AI in psychotherapy cannot be reduced to technical performance. We outline in general terms how the European framework, consisting of the General Data Protection Regulation, the Medical Device Regulation, and the Artificial Intelligence Act, addresses these concerns and where gaps remain. From a meaning-centered perspective, we emphasize that responsibility, a central category of Frankl's logotherapy, cannot be delegated to a machine. We conclude with principles for the responsible design, evaluation, and clinical use of AI in psychotherapy.

Keywords: artificial intelligence · psychotherapy ethics · responsibility · data protection · EU AI Act

1 Introduction

La psychothérapie s'est toujours appuyée sur des technologies d'une forme ou d'une autre, du dossier clinique écrit au téléphone et à la visioconférence. La vague actuelle d'intelligence artificielle (IA) se distingue toutefois sur un point décisif : les systèmes

fondés sur l'apprentissage automatique et les grands modèles de langage ne se contentent plus de transmettre ou de stocker la communication, mais génèrent des réponses, classent des énoncés et produisent des prédictions susceptibles d'influencer les décisions cliniques (Torous et al., 2021). Chacune de ces fonctions touche au cœur de la relation thérapeutique, qui repose sur la confiance et la confidentialité.

Les premières synthèses du domaine ont souligné des questions de compétence, de responsabilité juridique, de vie privée et d'une possible érosion du contact humain (Fiske et al., 2019; Luxton, 2014). La présente contribution reprend ces questions et les organise selon cinq domaines : l'autonomie, la responsabilité, la protection des données et la transparence, la protection des utilisateurs vulnérables et la régulation. Plutôt que de proposer une analyse juridique complète, nous cherchons à clarifier la structure éthique des problèmes et à indiquer comment le droit européen y répond. Nous nous appuyons tout au long sur la tradition centrée sur le sens, qui place la responsabilité personnelle au centre de l'existence humaine (Frankl, 1946/1985).

2 Autonomie et consentement éclairé

Le respect de l'autonomie est l'un des quatre principes que Beauchamp et Childress (2019) proposent comme cadre de l'éthique biomédicale, aux côtés de la bienfaisance, de la non-malfaisance et de la justice. En psychothérapie, l'autonomie est à la fois le droit du patient de décider de son traitement sur la base d'une information adéquate et un objectif thérapeutique, puisque de nombreuses formes de psychothérapie visent à renforcer l'autodétermination.

En ce qui concerne le consentement éclairé, les patients doivent savoir s'ils communiquent avec un être humain ou avec un logiciel, ce que le système peut et ne peut pas faire, comment leurs données sont traitées et qui est responsable du service. Les systèmes conversationnels sont conçus pour produire un langage fluide et apparemment empathique, ce qui peut conduire les utilisateurs à attribuer compréhension et sollicitude là où n'opère qu'une génération statistique de texte (Bender et al., 2021). Un consentement obtenu sous l'effet de telles attributions erronées est éthiquement fragile, même lorsque les exigences formelles sont remplies.

En ce qui concerne l'autonomie comme objectif thérapeutique, la préoccupation est plus subtile. Des systèmes optimisés pour l'engagement peuvent favoriser la dépendance plutôt que l'indépendance, et des caractéristiques de conception persuasive peuvent orienter les utilisateurs vers certains comportements sans leur adhésion réfléchie (Floridi et al., 2018). Une application devrait donc être jugée non seulement sur la réduction des symptômes à court terme, mais aussi sur sa capacité à soutenir le jugement propre de l'utilisateur et, le cas échéant, à encourager le recours à une aide humaine.

3 Responsabilité et lacune de responsabilité

Lorsqu'un thérapeute commet une erreur, des structures établies de responsabilité professionnelle, juridique et morale s'appliquent. Leur comportement résulte des données d'entraînement, des choix de conception et du contexte d'utilisation, et il n'est souvent pas entièrement prévisible, même pour leurs développeurs. Matthias (2004) a décrit la situation qui en résulte comme une lacune de responsabilité : plus un système apprenant agit de manière autonome, plus il devient difficile d'attribuer ses résultats à une personne déterminée.

Pour la psychothérapie, cette lacune n'est pas seulement un problème juridique. Les grands modèles de langage peuvent produire des affirmations plausibles mais fausses, phénomène largement discuté sous le nom d'hallucination (Ji et al., 2023). Si une telle affirmation concerne la médication, le diagnostic ou une crise suicidaire, les conséquences peuvent être graves. Une exigence éthique minimale consiste donc à inscrire les fonctions d'IA cliniquement pertinentes dans une chaîne claire de responsabilité humaine : le fabricant pour la conception et la validation, l'institution pour le choix et la surveillance de l'outil, et le clinicien traitant pour les décisions prises dans le cas individuel.

Dans une perspective logothérapeutique, la responsabilité n'est pas seulement une obligation imposée de l'extérieur, mais une caractéristique constitutive de l'existence humaine. Frankl (1946/1985) comprenait l'être humain comme être responsable, c'est-à-dire comme la capacité de répondre aux exigences d'une situation concrète. Une machine peut générer des sorties, mais elle ne peut en répondre en ce sens existentiel. Cela conforte la position largement partagée selon laquelle l'IA devrait assister, et non remplacer, le jugement d'un clinicien responsable, et met en garde contre des cliniciens qui s'en remettraient aux recommandations algorithmiques sans les examiner.

4 Protection des données, transparence et justice

Les données de santé mentale comptent parmi les informations personnelles les plus sensibles. En vertu du règlement général sur la protection des données (RGPD), les données concernant la santé appartiennent aux catégories particulières de données à caractère personnel dont le traitement est interdit, sauf si des conditions spécifiques sont remplies (Regulation (EU) 2016/679, 2016). Les préoccupations éthiques dépassent néanmoins la seule conformité juridique : des fournisseurs commerciaux peuvent être incités à utiliser les données conversationnelles pour le développement de produits, et la frontière entre service de santé et produit de consommation est souvent floue pour les utilisateurs (Fiske et al., 2019).

Les utilisateurs devraient être informés lorsqu'ils interagissent avec un système d'IA, et les cliniciens devraient comprendre le fondement, les limites et l'état de validation des outils qu'ils emploient. Une explicabilité complète des modèles complexes est peut-être hors d'atteinte, mais une transparence significative sur la destination, les données d'entraînement, les modes de défaillance connus et les preuves disponibles est réalisable et éthiquement requise (Floridi et al., 2018; Mittelstadt et al., 2016).

La question de la justice y est étroitement liée. Des algorithmes entraînés sur des données issues de populations particulières peuvent être moins performants pour d'autres, et des variables cibles en apparence neutres peuvent reproduire des inégalités structurelles. Obermeyer et al. (2019) ont montré, pour un algorithme largement utilisé dans la gestion des soins, que l'emploi des coûts de santé comme indicateur indirect des besoins de santé désavantageait les patients noirs. Des risques comparables existent dans les soins de santé mentale, où l'expression de la détresse diffère selon les groupes culturels et linguistiques. Un examen systématique des performances selon les sous-groupes devrait donc faire partie de toute évaluation.

5 Utilisateurs vulnérables et situations de crise

Les personnes qui cherchent une aide psychologique, en particulier les mineurs et les personnes en crise aiguë, se trouvent souvent dans un état de vulnérabilité accrue. Une étude fréquemment citée de Miner et al. (2016) a constaté que des agents conversationnels largement disponibles sur smartphone répondaient de manière incohérente et souvent inadéquate à des énoncés portant sur les idées suicidaires, la dépression et la violence interpersonnelle. Bien que les systèmes examinés n'aient pas été conçus comme des outils thérapeutiques, l'étude illustre un problème général : les utilisateurs peuvent se tourner vers la technologie disponible dans les moments de crise, quelle qu'en soit la destination.

Sur le plan éthique, cela signifie que les fournisseurs d'applications de santé mentale ont des devoirs de vigilance particuliers. Ceux-ci comprennent la détection fiable des signaux de crise, l'orientation claire vers une aide humaine et les services d'urgence, la protection contre les contenus préjudiciables et la retenue dans les allégations d'efficacité. Les personnes qui traversent un vide existentiel, au sens de Frankl, peuvent être particulièrement réceptives à un interlocuteur constamment disponible et approbateur. Un système qui ne répond que par la validation peut soulager la solitude à court terme tout en laissant intacte la question du sens qui la sous-tend.

6 Le cadre réglementaire européen

Dans l'Union européenne, trois instruments juridiques sont particulièrement pertinents. Premièrement, le RGPD régit le traitement des données de santé, y compris les exigences relatives à une base juridique, à la minimisation des données, à la limitation des finalités et aux droits des personnes concernées (Regulation (EU) 2016/679, 2016). Deuxièmement, le règlement relatif aux dispositifs médicaux s'applique aux logiciels dont la destination, telle que précisée par le fabricant, comprend des fins médicales comme le diagnostic, la prévention, la surveillance ou le traitement d'une maladie (Regulation (EU) 2017/745, 2017). De tels logiciels doivent faire l'objet d'une évaluation de la conformité adaptée à leur classe de risque avant leur mise sur le marché.

Troisièmement, le règlement sur l'intelligence artificielle, entré en vigueur en 2024 et applicable par étapes, introduit un cadre fondé sur les risques pour les systèmes d'IA (Regulation (EU) 2024/1689, 2024). Il interdit certaines pratiques, notamment les systèmes d'IA qui recourent à des techniques manipulatrices ou exploitent des vulnérabilités liées à l'âge, au handicap ou à la situation sociale ou économique de manière à causer un préjudice important. Les systèmes d'IA qui sont eux-mêmes des dispositifs médicaux ou des composants de sécurité de tels dispositifs, et qui sont soumis à une évaluation de la conformité par un tiers, sont classés à haut risque et doivent satisfaire à des exigences en matière de gestion des risques, de qualité des données, de

documentation, de contrôle humain et d'exactitude. Le règlement établit en outre des obligations de transparence, par exemple l'obligation d'informer les personnes lorsqu'elles interagissent directement avec un système d'IA, sauf si cela ressort clairement du contexte.

D'importantes lacunes subsistent néanmoins. De nombreuses applications de bien-être, de coaching ou de compagnie ne sont délibérément pas commercialisées à des fins médicales et échappent ainsi au droit des dispositifs médicaux, bien qu'elles soient utilisées par des personnes souffrant de problèmes de santé mentale. Les modèles de langage généralistes sont de même utilisés pour un soutien pour lequel ils n'ont pas été conçus. La qualification réglementaire dépend donc largement de la destination déclarée, alors que l'évaluation éthique doit tenir compte de l'usage effectif. La déontologie professionnelle, les recommandations cliniques et l'évaluation indépendante demeurent des compléments indispensables du droit (Torous et al., 2021).

7 Conclusion

Les questions éthiques soulevées par l'IA en psychothérapie ne se réduisent pas à l'exactitude ou à l'efficience. Elles concernent les conditions dans lesquelles les personnes peuvent faire confiance à une relation d'aide, prendre des décisions éclairées et rester les auteurs de leur propre vie. Plusieurs principes découlent de l'analyse : la transparence sur la nature artificielle et les limites d'un système ; un consentement éclairé qui prend au sérieux le risque d'attribution anthropomorphique erronée ; une répartition claire de la responsabilité humaine ; une protection stricte et un usage minimal des données sensibles ; un examen systématique des biais ; des protocoles de crise robustes ; et une évaluation indépendante avant toute diffusion large.

La régulation peut imposer certains de ces principes, mais elle ne peut remplacer la responsabilité professionnelle et personnelle de ceux qui développent, recommandent et utilisent de tels systèmes. La tradition centrée sur le sens nous rappelle que la question décisive n'est pas seulement ce que la technologie peut faire, mais à quoi elle sert. L'IA en psychothérapie est éthiquement justifiée dans la mesure où elle sert la personne, soutient sa capacité d'autodétermination responsable et maintient ouvert, plutôt que de le fermer, le chemin vers une authentique rencontre humaine.

Références

Beauchamp, T. L., & Childress, J. F. (2019). Principles of biomedical ethics (8th ed.). Oxford University Press.

Bender, E. M., Gebru, T., McMillan-Major, A., & Shmitchell, S. (2021). On the dangers of stochastic parrots: Can language models be too big? In Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency (pp. 610–623). Association for Computing Machinery. https://doi.org/10.1145/3442188.3445922

Fiske, A., Henningsen, P., & Buyx, A. (2019). Your robot therapist will see you now: Ethical implications of embodied artificial intelligence in psychiatry, psychology, and psychotherapy. Journal of Medical Internet Research, 21(5), e13216. https://doi.org/10.2196/13216

Floridi, L., Cowls, J., Beltrametti, M., Chatila, R., Chazerand, P., Dignum, V., Luetge, C., Madelin, R., Pagallo, U., Rossi, F., Schafer, B., Valcke, P., & Vayena, E. (2018). AI4People—An ethical framework for a good AI society: Opportunities, risks, principles, and recommendations. Minds and Machines, 28(4), 689–707. https://doi.org/10.1007/s11023-018-9482-5

Frankl, V. E. (1985). Man's search for meaning (Rev. and updated ed.). Washington Square Press. (Original work published 1946)

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of hallucination in natural language generation. ACM Computing Surveys, 55(12), Article 248. https://doi.org/10.1145/3571730

Luxton, D. D. (2014). Artificial intelligence in psychological practice: Current and future applications and implications. Professional Psychology: Research and Practice, 45(5), 332–339. https://doi.org/10.1037/a0034559

Matthias, A. (2004). The responsibility gap: Ascribing responsibility for the actions of learning automata. Ethics and Information Technology, 6(3), 175–183. https://doi.org/10.1007/s10676-004-3422-1

Miner, A. S., Milstein, A., Schueller, S., Hegde, R., Mangurian, C., & Linos, E. (2016). Smartphone-based conversational agents and responses to questions about mental health, interpersonal violence, and physical health. JAMA Internal Medicine, 176(5), 619–625. https://doi.org/10.1001/jamainternmed.2016.0400

Mittelstadt, B. D., Allo, P., Taddeo, M., Wachter, S., & Floridi, L. (2016). The ethics of algorithms: Mapping the debate. Big Data & Society, 3(2). https://doi.org/10.1177/2053951716679679

Obermeyer, Z., Powers, B., Vogeli, C., & Mullainathan, S. (2019). Dissecting racial bias in an algorithm used to manage the health of populations. Science, 366(6464), 447–453. https://doi.org/10.1126/science.aax2342

Regulation (EU) 2016/679 of the European Parliament and of the Council of 27 April 2016 on the protection of natural persons with regard to the processing of personal data and on the free movement of such data, and repealing Directive 95/46/EC (General Data Protection Regulation). (2016). Official Journal of the European Union, L 119, 1–88.

Regulation (EU) 2017/745 of the European Parliament and of the Council of 5 April 2017 on medical devices. (2017). Official Journal of the European Union, L 117, 1–175.

Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act). (2024). Official Journal of the European Union, L, 2024/1689.

Torous, J., Bucci, S., Bell, I. H., Kessing, L. V., Faurholt-Jepsen, M., Whelan, P., Carvalho, A. F., Keshavan, M., Linardon, J., & Firth, J. (2021). The growing field of digital psychiatry: Current evidence and the future of apps, social media, chatbots, and virtual reality. World Psychiatry, 20(3), 318–335. https://doi.org/10.1002/wps.20883

CITATION (VERSION ORIGINALE)

Ashford, S. R., Pazer, S., & Whitcombe, E. M. (2026). Ethics and Regulation of Artificial Intelligence in Psychotherapy: Autonomy, responsibility, privacy, and the protection of vulnerable users under emerging European law. Journal of Meaning-Centered Psychology, 1(3), 56–59.

LICENCE, CORRESPONDANCE ET UTILISATION DE L'IA

Publié en libre accès sous licence Creative Commons Attribution 4.0 International (CC BY 4.0). Correspondance : rédaction de la revue. Cet article a été rédigé avec l'aide de l'IA générative et relu par les auteurs, qui en assument l'entière responsabilité.