Revue de psychologie centrée sur le sens
PUBLIÉE PAR L'INSTITUT DE PSYCHOLOGIE CENTRÉE SUR LE SENS

Volume 1 · Numéro 3 · octobre 2026
p. 60–63 (Original) · Libre accès · CC BY 4.0

ARTICLE DE SYNTHÈSE

Traitement automatique du langage appliqué aux séances de psychothérapie

Une revue narrative du codage automatisé de la fidélité, de la détection de l'empathie et du retour d'information aux thérapeutes

Eleanor M. Whitcombe, Sora Pazer et Samuel R. Ashford
Institut de psychologie centrée sur le sens

Traduction française. La version originale anglaise fait foi.

RÉSUMÉ

La recherche sur le processus en psychothérapie a longtemps reposé sur le codage humain d'enregistrements de séances, une procédure fiable mais exigeante en travail qui atteint rarement les soins courants. Le traitement automatique du langage naturel (TALN) ouvre la perspective d'analyser les conversations thérapeutiques à grande échelle. Cette revue narrative résume les principales lignes de recherche sur l'analyse automatisée des séances de psychothérapie. Nous décrivons d'abord le codage automatisé de la fidélité à l'entretien motivationnel, des premières études de classification de textes jusqu'aux chaînes de traitement automatisées qui combinent reconnaissance de la parole, identification des locuteurs et codage comportemental. Nous passons ensuite en revue les travaux sur la détection de l'empathie et sur d'autres variables de processus comme l'alliance thérapeutique, et décrivons des systèmes qui restituent aux thérapeutes des indicateurs générés automatiquement ou proposent des suggestions au cours de conversations écrites. Les données suggèrent que certains comportements des thérapeutes peuvent être codés avec un accord prometteur avec des évaluateurs humains, tandis que les construits relationnels restent plus difficiles à saisir. Nous discutons des limites relatives à la validité, à la généralisabilité entre contextes et langues, à une possible réactivité aux indicateurs et à la protection de données de séance hautement sensibles. Dans une perspective centrée sur le sens, nous soutenons que ces outils peuvent soutenir une pratique réflexive, mais ne doivent remplacer ni le jugement clinique ni la rencontre personnelle au cœur de la psychothérapie.

Mots-clés : traitement automatique du langage naturel · entretien motivationnel · fidélité thérapeutique · empathie · recherche sur le processus psychothérapeutique

ABSTRACT

Process research in psychotherapy has long depended on human coding of session recordings, a reliable but labor-intensive procedure that rarely reaches routine care. Natural language processing (NLP) offers the prospect of analyzing therapeutic conversations at scale. This narrative review summarizes the main lines of research on the automated analysis of psychotherapy sessions. We first describe the automated coding of motivational interviewing fidelity, from early text classification studies to automated pipelines that combine speech recognition, speaker identification, and behavioral coding. We then review work on empathy detection and on other process variables such as the working alliance, and describe systems that return automatically generated metrics to therapists or offer suggestions during text-based conversations. The evidence suggests that selected therapist behaviors can be coded with promising agreement with human raters, whereas relational constructs remain more difficult to capture. We discuss limitations regarding validity, generalizability across settings and languages, possible reactivity to metrics, and the protection of highly sensitive session data. From a meaning-centered perspective, we argue that such tools can support reflective practice but must not replace clinical judgment or the personal encounter at the heart of psychotherapy.

Keywords: natural language processing · motivational interviewing · treatment fidelity · empathy · psychotherapy process research

1 Introduction

Ce qui se passe dans la salle de thérapie a longtemps été difficile à étudier à grande échelle. La recherche sur le processus dépend d'enregistrements que des évaluateurs formés codent selon des manuels comportementaux, une procédure fiable lorsqu'elle est bien conduite, mais longue et coûteuse. En conséquence, les soins courants bénéficient rarement d'un retour systématique sur la qualité des conversations thérapeutiques, et la recherche sur le processus reste limitée à des échantillons relativement restreints (Atkins et al., 2014).

Le traitement automatique du langage naturel (TALN), c'est-à-dire l'analyse computationnelle de la langue parlée et écrite, promet de modifier cette situation. Au cours de la dernière décennie, des groupes de recherche ont développé des modèles qui transcrivent les séances, identifient les locuteurs et attribuent des codes comportementaux à des énoncés individuels. Cette revue narrative résume les principales lignes de cette recherche, en se concentrant sur la fidélité à l'entretien motivationnel (EM), la détection de l'empathie et le retour d'information aux thérapeutes, puis examine les questions de validité et de protection des données auxquelles il faut répondre avant que de tels outils n'entrent dans la pratique courante. La revue est sélective plutôt que systématique ; une cartographie plus large de l'apprentissage automatique dans la recherche en psychothérapie est proposée par Aafjes-van Doorn et al. (2021).

2 Pourquoi le codage du processus importe

La fidélité thérapeutique, c'est-à-dire la mesure dans laquelle un thérapeute met en œuvre une intervention comme prévu et avec compétence, est centrale tant pour la recherche que pour la formation. Les données méta-analytiques sur l'association entre l'adhésion ou la compétence du thérapeute et les résultats sont moins cohérentes qu'on ne le suppose souvent (Webb et al., 2010), mais le suivi de la fidélité reste indispensable pour interpréter les essais et pour garantir que ce qui est diffusé correspond à ce qui a été testé. L'empathie du thérapeute figure, quant à elle, parmi les facteurs relationnels le plus régulièrement associés aux résultats (Elliott et al., 2018).

L'EM constitue un cas test particulièrement approprié pour le codage automatisé. Il s'agit d'une approche bien spécifiée, fondée sur la conversation, dans laquelle le comportement verbal du thérapeute, comme les questions ouvertes, les reflets complexes et les valorisations, est censé façonner le discours de changement du client (Miller & Rollnick, 2013). Sa fidélité est évaluée à l'aide de systèmes de codage établis tels que le Motivational Interviewing Treatment Integrity code, dont la version actuelle combine des évaluations globales et des décomptes de comportements spécifiques (Moyers et al., 2016). Le codage humain avec de tels instruments exige une formation approfondie et un temps considérable par séance, ce qui en limite l'usage dans les soins courants.

3 Codage automatisé de la fidélité à l'entretien motivationnel

Atkins et al. (2014) ont montré très tôt que la classification statistique de textes pouvait approcher les codes humains de l'EM. À partir de transcriptions de séances de counseling, ils ont entraîné des modèles thématiques pour prédire des codes au niveau des énoncés et des évaluations au niveau des séances, et ont rapporté que les modèles reproduisaient assez bien le codage humain pour plusieurs codes, mais pas pour tous. Tanana et al. (2016) ont ensuite comparé différentes méthodes de TALN pour le codage des énoncés de l'EM et ont constaté que l'accord avec les codeurs humains variait considérablement selon les codes, certains comportements étant reconnus de manière plus fiable que d'autres.

Des travaux ultérieurs sont passés de transcriptions produites manuellement à des chaînes de traitement automatisées. Flemotomos et al. (2022) ont décrit un système qui traite des enregistrements audio par détection de l'activité vocale, segmentation en locuteurs, reconnaissance automatique de la parole et identification des rôles, avant d'attribuer des codes comportementaux et d'estimer des indicateurs de qualité au niveau des séances. Appliquée à des enregistrements issus d'un contexte réel de counseling, une telle chaîne permet en principe d'évaluer un grand nombre de séances sans transcription humaine. Les chaînes à plusieurs étapes posent en outre un problème spécifique : les erreurs peuvent se propager d'une étape à l'autre, de sorte que des imprécisions dans la reconnaissance de la parole ou l'attribution des locuteurs peuvent affecter les codes obtenus.

Prises ensemble, ces études suggèrent que le codage automatisé de l'EM est réalisable et que l'accord avec les évaluateurs humains peut approcher la fidélité interjuges humaine pour certains codes et indicateurs au niveau des séances. Dans le même temps, les performances sont inégales, et la plupart des modèles ont été développés et testés sur un nombre limité de

jeux de données, de contextes et de langues, principalement l'anglais. La question de savoir si des modèles entraînés dans un contexte se généralisent à d'autres populations, approches thérapeutiques et langues reste largement ouverte.

4 Détection de l'empathie et autres variables de processus

L'empathie est plus difficile à opérationnaliser que des comportements spécifiques de l'EM, car elle dépend du sens d'un énoncé dans son contexte et pas seulement de caractéristiques de surface. Xiao et al. (2015) ont néanmoins montré que l'empathie du thérapeute évaluée par des observateurs dans des séances de counseling en addictologie pouvait être prédite à partir de caractéristiques de la parole et du langage, dans une mesure suggérant un potentiel pratique. Pour le soutien par les pairs en format écrit, Sharma et al. (2020) ont proposé un cadre distinguant les réactions émotionnelles, les interprétations et les explorations comme mécanismes de communication de l'empathie, et ont développé des modèles pour les identifier dans des conversations en ligne.

Au-delà de l'empathie, les méthodes de TALN ont été appliquées à d'autres construits de processus. Goldberg et al. (2020) ont utilisé des transcriptions de séances pour prédire l'alliance thérapeutique évaluée par les clients et ont constaté que les modèles saisissaient une partie de la variance des évaluations de l'alliance, bien que la précision prédictive soit restée modeste. La revue exploratoire d'Aafjes-van Doorn et al. (2021) a documenté un domaine en croissance rapide mais méthodologiquement hétérogène, recourant fréquemment à de petits échantillons et à une validation externe limitée.

Ces résultats illustrent une tension fondamentale. Des construits tels que l'empathie et l'alliance sont relationnels et en partie subjectifs ; ils sont vécus par les clients et inférés par les observateurs. Un modèle qui prédit des évaluations d'observateurs à partir de textes apprend les régularités d'une tradition de codage particulière, et non l'empathie en tant que telle. Ses résultats devraient donc être interprétés comme des estimations de la manière dont des évaluateurs formés jugeraient probablement une conversation, avec toutes les hypothèses que cela implique.

5 De la mesure au retour d'information

La principale promesse pratique du codage automatisé réside dans le retour d'information. Imel et al. (2019) ont développé un prototype qui fournissait aux conseillers, après une séance, des indicateurs de fidélité à l'EM générés automatiquement, et en ont examiné la faisabilité de conception ; les participants ont généralement jugé ce retour compréhensible et potentiellement utile pour leur développement professionnel. De tels systèmes pourraient rendre accessible de façon continue un retour fondé sur la performance, qui n'est autrement disponible que dans le cadre d'une formation supervisée.

Une étape supplémentaire est le soutien en temps réel. Sharma et al. (2023) ont rapporté, dans un essai randomisé mené sur une plateforme de soutien par les pairs en ligne, qu'un système d'IA suggérant comment rendre les réponses plus empathiques augmentait l'empathie évaluée des conversations, en particulier chez les aidants qui avaient des difficultés à exprimer de l'empathie. Cette étude portait sur des pairs aidants et non sur des psychothérapeutes, et l'empathie était évaluée au niveau de messages écrits ; ses implications pour la pratique clinique ne doivent donc pas être surestimées. Elle illustre néanmoins que la frontière entre mesure et intervention s'estompe dès lors que des modèles proposent des suggestions au cours d'une conversation.

6 Validité, protection des données et questions éthiques

Plusieurs questions de validité doivent être résolues avant que le codage automatisé puisse servir à des décisions lourdes de conséquences. Premièrement, l'accord avec des codeurs humains est un critère nécessaire mais insuffisant ; les codes humains ont eux-mêmes une fiabilité limitée, et un modèle qui les reproduit en reproduit aussi les erreurs et les biais. Deuxièmement, la validité prédictive, c'est-à-dire la question de savoir si les indicateurs automatisés sont liés aux résultats des clients, a rarement été examinée. Troisièmement, les performances doivent être testées selon les groupes de clients, les dialectes et les langues, car la reconnaissance de la parole et les modèles de langage peuvent fonctionner moins bien pour des locuteurs sous-représentés dans les données d'entraînement. Enfin, si des scores de fidélité étaient utilisés pour l'évaluation ou la rémunération, les thérapeutes pourraient ajuster leur comportement verbal à l'indicateur plutôt qu'au client.

La protection des données n'est pas moins importante. Les enregistrements de thérapie contiennent des informations de santé hautement sensibles sur les clients et, souvent, sur des tiers. Dans l'Union européenne, ces données relèvent des catégories particulières de données à caractère personnel protégées par le règlement général sur la

protection des données (RGPD), qui exige une base juridique valable, la limitation des finalités, la minimisation des données ainsi que des mesures techniques et organisationnelles appropriées (Regulation (EU) 2016/679, 2016). L'enregistrement de séances en vue d'une analyse automatisée requiert un consentement explicite et éclairé, un stockage sécurisé et des règles claires sur la conservation et l'utilisation secondaire, par exemple pour l'entraînement de modèles. Le traitement local et la désidentification peuvent réduire ces risques, mais non les éliminer, car le contenu d'une conversation peut lui-même être identifiant.

Enfin, l'avènement des grands modèles de langage transforme le domaine. Ces modèles peuvent générer des résumés, des retours et des codes avec peu d'entraînement spécifique à la tâche, mais ils produisent aussi un texte fluide dont le rapport avec la conversation réelle n'est pas garanti (Bender et al., 2021). Les normes de validation établies pour les modèles de codage spécialisés, y compris la comparaison avec des évaluations humaines et la transparence sur les taux d'erreur, devraient s'appliquer également à ces systèmes plus généraux.

7 Conclusion

Le TALN appliqué aux séances de psychothérapie est passé d'études de faisabilité à des chaînes de traitement automatisées et à de premiers systèmes de retour d'information. Les données suggèrent que certains comportements des thérapeutes, en particulier dans l'EM, peuvent être codés automatiquement avec une précision prometteuse, et que le retour automatisé est accepté par les cliniciens dans les premières études. Les preuves qu'un tel retour améliore les compétences thérapeutiques et, en fin de compte, les résultats des clients dans les soins courants restent limitées.

Dans une perspective centrée sur le sens, ces outils méritent une évaluation nuancée. Ils peuvent aider les thérapeutes à percevoir plus clairement leurs propres habitudes conversationnelles et soutenir ainsi une pratique réflexive. Ils ne peuvent cependant pas saisir ce qu'une conversation signifie pour la personne qui cherche de l'aide. Utilisées comme instruments d'apprentissage dans des conditions de consentement éclairé et de protection stricte des données, les analyses automatisées peuvent enrichir la formation et l'assurance qualité ; utilisées comme substituts du jugement clinique ou comme instruments de contrôle, elles risquent de réduire la rencontre thérapeutique à ce qui peut être compté.

Références

Aafjes-van Doorn, K., Kamsteeg, C., Bate, J., & Aafjes, M. (2021). A scoping review of machine learning in psychotherapy research. Psychotherapy Research, 31(1), 92–116. https://doi.org/10.1080/10503307.2020.1808729

Atkins, D. C., Steyvers, M., Imel, Z. E., & Smyth, P. (2014). Scaling up the evaluation of psychotherapy: Evaluating motivational interviewing fidelity via statistical text classification. Implementation Science, 9, 49. https://doi.org/10.1186/1748-5908-9-49

Bender, E. M., Gebru, T., McMillan-Major, A., & Shmitchell, S. (2021). On the dangers of stochastic parrots: Can language models be too big? In Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency (pp. 610–623). Association for Computing Machinery. https://doi.org/10.1145/3442188.3445922

Elliott, R., Bohart, A. C., Watson, J. C., & Murphy, D. (2018). Therapist empathy and client outcome: An updated meta-analysis. Psychotherapy, 55(4), 399–410. https://doi.org/10.1037/pst0000175

Flemotomos, N., Martinez, V. R., Chen, Z., Singla, K., Ardulov, V., Peri, R., Caperton, D. D., Gibson, J., Tanana, M. J., Georgiou, P., Van Epps, J., Lord, S. P., Hirsch, T., Imel, Z. E., Atkins, D. C., & Narayanan, S. (2022). Automated evaluation of psychotherapy skills using speech and language technologies. Behavior Research Methods, 54(2), 690–711. https://doi.org/10.3758/s13428-021-01623-4

Goldberg, S. B., Flemotomos, N., Martinez, V. R., Tanana, M. J., Kuo, P. B., Pace, B. T., Villatte, J. L., Georgiou, P. G., Van Epps, J., Imel, Z. E., Narayanan, S. S., & Atkins, D. C. (2020). Machine learning and natural language processing in psychotherapy research: Alliance as example use case. Journal of Counseling Psychology, 67(4), 438–448. https://doi.org/10.1037/cou0000382

Imel, Z. E., Pace, B. T., Soma, C. S., Tanana, M., Hirsch, T., Gibson, J., Georgiou, P., Narayanan, S., & Atkins, D. C. (2019). Design feasibility of an automated, machine-learning based feedback system for motivational interviewing. Psychotherapy, 56(2), 318–328. https://doi.org/10.1037/pst0000221

Miller, W. R., & Rollnick, S. (2013). Motivational interviewing: Helping people change (3rd ed.). Guilford Press.

Moyers, T. B., Rowell, L. N., Manuel, J. K., Ernst, D., & Houck, J. M. (2016). The Motivational Interviewing Treatment Integrity code (MITI 4): Rationale, preliminary reliability and validity. Journal of Substance Abuse Treatment, 65, 36–42. https://doi.org/10.1016/j.jsat.2016.01.001

Regulation (EU) 2016/679 of the European Parliament and of the Council of 27 April 2016 on the protection of natural persons with regard to the processing of personal data and on the free movement of such data, and repealing Directive 95/46/EC (General Data Protection Regulation). (2016). Official Journal of the European Union, L 119, 1–88.

Sharma, A., Lin, I. W., Miner, A. S., Atkins, D. C., & Althoff, T. (2023). Human–AI collaboration enables more empathic conversations in text-based peer-to-peer mental health support. Nature Machine Intelligence, 5(1), 46–57. https://doi.org/10.1038/s42256-022-00593-2

Sharma, A., Miner, A. S., Atkins, D. C., & Althoff, T. (2020). A computational approach to understanding empathy expressed in text-based mental health support. In Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (pp. 5263–5276). Association for Computational Linguistics. https://doi.org/10.18653/v1/2020.emnlp-main.425

Tanana, M., Hallgren, K. A., Imel, Z. E., Atkins, D. C., & Srikumar, V. (2016). A comparison of natural language processing methods for automated coding of motivational interviewing. Journal of Substance Abuse Treatment, 65, 43–50. https://doi.org/10.1016/j.jsat.2016.01.006

Webb, C. A., DeRubeis, R. J., & Barber, J. P. (2010). Therapist adherence/competence and treatment outcome: A meta-analytic review. Journal of Consulting and Clinical Psychology, 78(2), 200–211. https://doi.org/10.1037/a0018912

Xiao, B., Imel, Z. E., Georgiou, P. G., Atkins, D. C., & Narayanan, S. S. (2015). “Rate my therapist”: Automated detection of empathy in drug and alcohol counseling via speech and language processing. PLoS ONE, 10(12), e0143055. https://doi.org/10.1371/journal.pone.0143055

CITATION (VERSION ORIGINALE)

Whitcombe, E. M., Pazer, S., & Ashford, S. R. (2026). Natural Language Processing of Psychotherapy Sessions: A narrative review of automated fidelity coding, empathy detection, and feedback to therapists. Journal of Meaning-Centered Psychology, 1(3), 60–63.

LICENCE, CORRESPONDANCE ET UTILISATION DE L'IA

Publié en libre accès sous licence Creative Commons Attribution 4.0 International (CC BY 4.0). Correspondance : rédaction de la revue. Cet article a été rédigé avec l'aide de l'IA générative et relu par les auteurs, qui en assument l'entière responsabilité.