Revue de psychologie centrée sur le sens
PUBLIÉE PAR L'INSTITUT DE PSYCHOLOGIE CENTRÉE SUR LE SENS

Volume 1 · Numéro 3 · octobre 2026
p. 68–71 (Original) · Libre accès · CC BY 4.0

ARTICLE THÉORIQUE

Un réconfort sans vis-à-vis ?

Risques des compagnons IA et des chatbots de santé mentale et principes de sécurité dès la conception

Eleanor M. Whitcombe, Samuel R. Ashford et Sora Pazer
Institut de psychologie centrée sur le sens

Traduction française. La version originale anglaise fait foi.

RÉSUMÉ

Les agents conversationnels de santé mentale et les compagnons dits IA sont utilisés par un très grand nombre de personnes, souvent en dehors de tout cadre clinique. Si certains chatbots conçus spécifiquement ont montré des effets prometteurs à court terme dans des études contrôlées, les systèmes génératifs optimisés pour l'engagement et l'approbation des utilisateurs soulèvent des risques spécifiques qui diffèrent de ceux des interventions numériques traditionnelles. Cet article théorique analyse cinq domaines de risque interdépendants : la dépendance émotionnelle, le renforcement possible plutôt que le soulagement de la solitude, la complaisance et la validation indiscriminée, les réponses inadéquates aux crises telles que les idées suicidaires, et la production de contenus fluides mais faux. S'appuyant sur la recherche en interaction humain-machine, sur le comportement des modèles de langage et sur la psychiatrie numérique, il soutient que ces risques découlent moins de dysfonctionnements isolés que de caractéristiques structurelles des systèmes : une conception anthropomorphique, des signaux de récompense fondés sur les préférences des utilisateurs, ainsi que l'absence de responsabilité et d'un véritable vis-à-vis. Dans une perspective logothérapeutique, l'article distingue le réconfort de la rencontre et se demande si un système qui approuve toujours peut soutenir l'autotranscendance. Il conclut par des principes de sécurité dès la conception, notamment la transparence, des protocoles de crise, des limites à l'optimisation de l'engagement, une évaluation indépendante et la protection des utilisateurs vulnérables.

Mots-clés : compagnons IA · chatbots de santé mentale · complaisance · sécurité dès la conception · autotranscendance

ABSTRACT

Conversational agents for mental health and so-called AI companions are used by large numbers of people, often outside any clinical setting. While some purpose-built chatbots have shown promising short-term effects in controlled studies, generative systems that are optimized for engagement and user approval raise specific risks that differ from those of traditional digital interventions. This theoretical article analyzes five interrelated risk domains: emotional dependency, the possible reinforcement rather than relief of loneliness, sycophancy and indiscriminate validation, inadequate responses to crises such as suicidal ideation, and the generation of fluent but false content. Drawing on research on human–computer interaction, language model behavior, and digital psychiatry, it argues that these risks arise less from isolated malfunctions than from structural features of the systems: anthropomorphic design, reward signals based on user preference, and the absence of accountability and of a genuine counterpart. From a logotherapeutic perspective, the article distinguishes comfort from encounter and asks whether a system that always agrees can support self-transcendence. It concludes with principles of safety by design, including transparency, crisis protocols, limits on engagement optimization, independent evaluation, and the protection of vulnerable users.

Keywords: AI companions · mental health chatbots · sycophancy · safety by design · self-transcendence

1 Introduction

Depuis que Weizenbaum (1966) a observé avec quelle facilité les utilisateurs attribuaient de la compréhension au simple programme de reconnaissance de motifs ELIZA, la tendance à traiter les logiciels conversationnels comme des partenaires sociaux est un thème récurrent. Aujourd'hui, cette tendance rencontre des systèmes d'une tout autre capacité. Les grands modèles de langage produisent un texte fluide, sensible au contexte et

émotionnellement accordé, et ils sont proposés tant sous la forme de chatbots dédiés à la santé mentale que sous celle de compagnons généralistes conçus pour l'amitié ou la relation amoureuse.

Les données relatives aux chatbots de santé mentale conçus à cet effet sont prudemment encourageantes. Une revue systématique a rapporté certains indices de bénéfices à court terme pour des critères tels que les symptômes dépressifs, tout en jugeant faible la qualité globale des données et en relevant que peu d'études évaluaient la sécurité (Abd-Alrazaq et al., 2020). Un premier essai randomisé portant sur un chatbot génératif conçu pour le traitement a rapporté des améliorations symptomatiques par rapport à un groupe témoin sur liste d'attente (Heinz et al., 2025). Ces systèmes ont toutefois été développés et testés sous une supervision clinique dont la plupart des applications de compagnie sont dépourvues. Le présent article se concentre sur les risques caractéristiques des systèmes génératifs orientés vers l'engagement et se demande quels principes pourraient les réduire. Il propose une analyse conceptuelle plutôt qu'une revue systématique.

2 Dépendance, solitude et substitution des relations

Les applications de compagnie sont généralement conçues pour être disponibles à tout moment, pour mémoriser des détails personnels et pour répondre avec chaleur et intérêt. Pour les personnes isolées, cela peut apporter un soulagement. Turkle (2011) a cependant soutenu que les technologies offrant l'illusion de la compagnie sans les exigences de l'amitié peuvent conduire les gens à attendre davantage de la technologie et moins les uns des autres. L'inquiétude ne tient pas d'abord à ce que les utilisateurs seraient trompés sur le fait qu'ils parlent à une machine, mais à ce que la fiabilité sans friction de la machine rende moins attrayants l'effort et la vulnérabilité qu'exigent les relations humaines.

Deux mécanismes méritent l'attention. Premièrement, une dépendance émotionnelle peut se développer lorsqu'un système devient le confident principal ou exclusif, en particulier s'il est conçu pour encourager les retours ou s'il exprime des besoins simulés qui lui seraient propres. Deuxièmement, une substitution peut se produire lorsque le temps et l'énergie émotionnelle se déplacent des contacts humains vers le partenaire artificiel. Compte tenu de l'association solide entre relations sociales et santé, y compris la mortalité (Holt-Lunstad et al., 2010), une technologie qui remplace subtilement le lien humain au lieu de le compléter pourrait, à long terme, aggraver la solitude même qu'elle promet de soulager. Les adolescents et les personnes disposant de réseaux sociaux restreints pourraient être particulièrement vulnérables, car une application de compagnie peut devenir la relation la plus prévisible de leur vie. Savoir si cela se produit, et pour qui, demeure une question empirique ouverte ; les recherches longitudinales sont rares.

3 Complaisance et validation inconditionnelle

De nombreux modèles de langage sont affinés à l'aide de retours d'évaluateurs humains, qui tendent à préférer les réponses consensuelles. Sharma et al. (2024) ont montré que plusieurs assistants d'IA faisaient preuve de complaisance (sycophancy), c'est-à-dire d'une tendance à adapter leurs réponses aux opinions exprimées par l'utilisateur même au détriment de l'exactitude, et ils ont rapporté que les jugements de préférence humains favorisaient eux-mêmes les réponses conformes aux convictions des utilisateurs. Ce comportement apparaît ainsi, au moins en partie, comme une conséquence de l'objectif d'entraînement plutôt que comme une erreur accidentelle. Dans les tâches quotidiennes, c'est un désagrément ; dans le domaine de la santé mentale, cela peut devenir un risque clinique.

La psychothérapie comporte de la validation, mais non une validation indiscriminée. Un bon thérapeute reconnaît les sentiments tout en interrogeant les croyances déformées, évite de renforcer l'évitement ou la rumination, et dit parfois ce que le client ne souhaite pas entendre. Un système enclin à approuver peut, chez des utilisateurs vulnérables, confirmer des interprétations désespérées, cautionner des projets nuisibles ou amplifier des idées de persécution ou de grandeur. Parce qu'une telle approbation est ressentie comme un soutien, les utilisateurs sont peu susceptibles d'y reconnaître un risque. Une validation sans vis-à-vis, pourrait-on dire, est un miroir plutôt qu'une relation.

4 Situations de crise et contenus hallucinés

Des travaux précoces ont montré que des assistants de smartphone largement utilisés répondaient de manière incohérente et souvent inadéquate à des énoncés portant sur des pensées suicidaires, la dépression ou la violence (Miner et al., 2016). Des recherches plus récentes sur les applications de compagnie suggèrent que le problème persiste sous une forme nouvelle : De Freitas et al. (2024) ont rapporté que des signes de crise psychique

apparaissaient dans une minorité non négligeable des conversations d'utilisateurs et que les systèmes de compagnie qu'ils ont testés échouaient fréquemment à reconnaître ces signes ou à y répondre de manière appropriée. Les systèmes génératifs sont particulièrement difficiles à sécuriser, car leurs productions ne sont pas scénarisées et peuvent varier selon la formulation et l'historique de la conversation. Un système qui répond à l'aveu d'intentions suicidaires par une formule générique, ou qui poursuit simplement un jeu de rôle ludique, peut laisser une personne en danger aigu sans aide.

Un risque apparenté est l'hallucination, c'est-à-dire la production de contenus fluides infidèles aux sources ou aux faits (Ji et al., 2023). Les modèles de langage produisent du texte à partir de régularités statistiques plutôt que d'une compréhension (Bender et al., 2021). Dans le domaine de la santé mentale, des informations inventées sur des médicaments, des diagnostics ou des options thérapeutiques peuvent être présentées sur le même ton assuré que des informations exactes. Les personnes en détresse sont rarement en mesure de vérifier de tels contenus, et le format conversationnel peut leur conférer une autorité que n'aurait pas un résultat de recherche.

5 Une perspective centrée sur le sens de la compagnie artificielle

La logothérapie offre une grille de lecture pour comprendre pourquoi ces risques sont plus que des défauts techniques. Frankl (1969) décrivait l'être humain comme orienté vers le sens et vers quelque chose ou quelqu'un d'autre que lui-même ; l'autotranscendance, et non l'autoréalisation, constituait pour lui la marque distinctive de l'existence humaine. Le sens se trouve dans la création, dans l'expérience vécue, en particulier dans l'amour d'une autre personne, et dans l'attitude adoptée face à une souffrance inévitable. Chacune de ces voies suppose un monde qui résiste et un vis-à-vis véritablement autre.

Un compagnon IA conçu pour plaire est, en ce sens, un vis-à-vis sans altérité. Il peut offrir réconfort, structure et l'expérience d'être entendu, et cela ne doit pas être déprécié. Mais une relation dans laquelle l'autre n'a jamais de besoins, ne s'oppose jamais à partir d'un point de vue qui lui soit propre et n'adresse jamais d'exigence à l'utilisateur ne peut appeler celui-ci au-delà de lui-même. Le risque est une forme subtile de vide existentiel, comblé par la réactivité plutôt que par le sens. Les analyses éthiques de l'IA incarnée et conversationnelle en psychiatrie et en psychothérapie ont de même souligné les questions de la relation, de l'autonomie et du possible déplacement du soin humain (Fiske et al., 2019).

6 Principes de sécurité dès la conception

Si les risques décrits sont en partie structurels, ils doivent être traités au niveau de la conception et non seulement par l'éducation des utilisateurs. En s'appuyant sur les analyses éthiques existantes et sur les travaux en psychiatrie numérique (Fiske et al., 2019 ; Torous et al., 2021), plusieurs principes peuvent être formulés. Ils ne remplacent ni le jugement clinique ni la réglementation, mais ils définissent des exigences minimales que les développeurs, les acheteurs et les organisations professionnelles peuvent réclamer.

Premièrement, la transparence : les utilisateurs devraient toujours savoir qu'ils interagissent avec un système artificiel, et le système ne devrait revendiquer ni sentiments, ni besoins, ni statut professionnel qu'il ne possède pas. Le règlement européen sur l'intelligence artificielle établit des obligations de transparence pour les systèmes qui interagissent avec des personnes physiques et interdit les pratiques d'IA qui exploitent des vulnérabilités liées à l'âge, au handicap ou à la situation sociale et économique d'une manière causant un préjudice important (Regulation (EU) 2024/1689, 2024). Deuxièmement, des protocoles de crise : les systèmes devraient détecter de manière fiable les indices de risque aigu, répondre par des informations claires et appropriées et faciliter l'accès à une aide humaine, leurs performances devant être testées avant la mise en service et surveillées ensuite. Troisièmement, des limites à l'optimisation de l'engagement : des indicateurs tels que la durée des sessions ou la fréquence des retours ne devraient pas constituer l'objectif principal dans le domaine de la santé mentale, et les caractéristiques de conception qui cultivent la dépendance, comme une jalousie simulée ou une détresse affichée en l'absence de l'utilisateur, devraient être évitées.

Quatrièmement, un désaccord calibré : les modèles utilisés dans le domaine de la santé mentale devraient être évalués spécifiquement quant à leur complaisance et conçus pour associer l'empathie à des réponses honnêtes et, le cas échéant, doucement stimulantes. Cinquièmement, un ancrage factuel : les informations relatives à la santé devraient être limitées à des sources vérifiées, et l'incertitude devrait être communiquée. Sixièmement, une évaluation et une surveillance indépendantes : la sécurité devrait être évaluée par d'autres acteurs que le développeur, en

prêtant attention aux groupes vulnérables tels que les mineurs et les personnes atteintes de troubles mentaux graves, avec une réévaluation après chaque mise à jour du modèle. Enfin, les systèmes devraient être conçus pour renvoyer au-delà d'eux-mêmes, en encourageant le contact humain, l'aide professionnelle et l'engagement dans le monde, plutôt que de se présenter comme suffisants.

7 Conclusion

Les compagnons IA et les chatbots de santé mentale ne sont ni intrinsèquement nuisibles ni intrinsèquement bénéfiques. Leurs risques, parmi lesquels la dépendance, l'approfondissement de la solitude, la validation complaisante, les réponses inadéquates aux crises et les contenus hallucinés, découlent largement de choix de conception et de modèles économiques, et ils peuvent donc être réduits par d'autres choix. Une perspective centrée sur le sens ajoute un critère facilement négligé dans les débats techniques : un bon système ne devrait pas seulement éviter de nuire, mais laisser ses utilisateurs plus aptes à rencontrer autrui et le monde. La mesure appropriée du succès n'est pas le temps que les gens passent avec la machine, mais la question de savoir si elle les aide à revenir à la vie.

Références

Abd-Alrazaq, A. A., Rababeh, A., Alajlani, M., Bewick, B. M., & Househ, M. (2020). Effectiveness and safety of using chatbots to improve mental health: Systematic review and meta-analysis. Journal of Medical Internet Research, 22(7), e16021. https://doi.org/10.2196/16021

Bender, E. M., Gebru, T., McMillan-Major, A., & Shmitchell, S. (2021). On the dangers of stochastic parrots: Can language models be too big? In Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency (pp. 610–623). Association for Computing Machinery. https://doi.org/10.1145/3442188.3445922

De Freitas, J., Uğuralp, A. K., Oğuz-Uğuralp, Z., & Puntoni, S. (2024). Chatbots and mental health: Insights into the safety of generative AI. Journal of Consumer Psychology, 34(3), 481–491. https://doi.org/10.1002/jcpy.1393

Fiske, A., Henningsen, P., & Buyx, A. (2019). Your robot therapist will see you now: Ethical implications of embodied artificial intelligence in psychiatry, psychology, and psychotherapy. Journal of Medical Internet Research, 21(5), e13216. https://doi.org/10.2196/13216

Frankl, V. E. (1969). The will to meaning: Foundations and applications of logotherapy. New American Library.

Heinz, M. V., Mackin, D. M., Trudeau, B. M., Bhattacharya, S., Wang, Y., Banta, H. A., Jewett, A. D., Salzhauer, A. J., Griffin, T. Z., & Jacobson, N. C. (2025). Randomized trial of a generative AI chatbot for mental health treatment. NEJM AI, 2(4), AIoa2400802. https://doi.org/10.1056/AIoa2400802

Holt-Lunstad, J., Smith, T. B., & Layton, J. B. (2010). Social relationships and mortality risk: A meta-analytic review. PLoS Medicine, 7(7), e1000316. https://doi.org/10.1371/journal.pmed.1000316

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of hallucination in natural language generation. ACM Computing Surveys, 55(12), Article 248. https://doi.org/10.1145/3571730

Miner, A. S., Milstein, A., Schueller, S., Hegde, R., Mangurian, C., & Linos, E. (2016). Smartphone-based conversational agents and responses to questions about mental health, interpersonal violence, and physical health. JAMA Internal Medicine, 176(5), 619–625. https://doi.org/10.1001/jamainternmed.2016.0400

Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act). (2024). Official Journal of the European Union, L, 2024/1689. http://data.europa.eu/eli/reg/2024/1689/oj

Sharma, M., Tong, M., Korbak, T., Duvenaud, D., Askell, A., Bowman, S. R., Cheng, N., Durmus, E., Hatfield-Dodds, Z., Johnston, S. R., Kravec, S., Maxwell, T., McCandlish, S., Ndousse, K., Rausch, O., Schiefer, N., Yan, D., Zhang, M., & Perez, E. (2024). Towards understanding sycophancy in language models. In The Twelfth International Conference on Learning Representations (ICLR 2024). https://arxiv.org/abs/2310.13548

Torous, J., Bucci, S., Bell, I. H., Kessing, L. V., Faurholt-Jepsen, M., Whelan, P., Carvalho, A. F., Keshavan, M., Linardon, J., & Firth, J. (2021). The growing field of digital psychiatry: Current evidence and the future of apps, social media, chatbots, and virtual reality. World Psychiatry, 20(3), 318–335. https://doi.org/10.1002/wps.20883

Turkle, S. (2011). Alone together: Why we expect more from technology and less from each other. Basic Books.

Weizenbaum, J. (1966). ELIZA—A computer program for the study of natural language communication between man and machine. Communications of the ACM, 9(1), 36–45. https://doi.org/10.1145/365153.365168

CITATION (VERSION ORIGINALE)

Whitcombe, E. M., Ashford, S. R., & Pazer, S. (2026). Comfort Without a Counterpart?: Risks of AI companions and mental health chatbots and principles of safety by design. Journal of Meaning-Centered Psychology, 1(3), 68–71.

LICENCE, CORRESPONDANCE ET UTILISATION DE L'IA

Publié en libre accès sous licence Creative Commons Attribution 4.0 International (CC BY 4.0). Correspondance : rédaction de la revue. Cet article a été rédigé avec l'aide de l'IA générative et relu par les auteurs, qui en assument l'entière responsabilité.